



Universidad
del Valle

**Sistema De Pregunta-Respuesta (QA) Basado en los Informes del Conflicto
Armado Colombiano**

Trabajo De Grado

JUAN DAVID TOVAR MONTOYA
202029032

juan.david.tovar@correounivalle.edu.co

Nombre del Director

RAUL E. GUTIERREZ DE PIÑEREZ REYES, Ph.D
raul.gutierrez@correounivalle.edu.co

Facultad de Ingeniería
Escuela de Ingeniería de Sistemas y Computación
Programa Académico de Ingeniería de Sistemas
Cali, Noviembre 29 2024

Resumen

Este trabajo de grado desarrolló un sistema de pregunta-respuesta (QA) enfocado en los informes de la Comisión para el Esclarecimiento de la Verdad, la Convivencia y la No Repetición (CEV), con el fin de facilitar el acceso, comprensión e interacción con la información sobre el conflicto armado colombiano. Para ello, se implementaron técnicas de Recuperación Aumentada con Generación (RAG) combinadas con modelos de lenguaje grandes (LLM) ajustados mediante técnicas de ajuste fino.

Se construyó un dataset QA con más de 2.800 instancias, generadas a partir de los 715 informes oficiales de la CEV. El conjunto de datos fue publicado en HuggingFace. Posteriormente, se entrenaron y evaluaron múltiples modelos LLM ligeros (como Mistral y Llama) con técnicas de ajuste fino eficiente (LoRA y QLoRA), priorizando la eficiencia en entornos de hardware limitado.

El sistema desarrollado, basado en FAISS para recuperación semántica y un modelo como generador, fue sometido a pruebas automáticas y evaluaciones con usuarios reales. Los resultados demostraron que el sistema ofrecía respuestas precisas y comprensibles, aunque con oportunidades de mejora en cobertura y profundidad.

Este trabajo demostró la viabilidad de construir herramientas accesibles y especializadas que contribuyen a la memoria histórica y a la democratización del conocimiento sobre el conflicto armado en Colombia, combinando procesamiento del lenguaje natural y técnicas modernas de inteligencia artificial.

Palabras clave: *conflicto armado colombiano, Comisión para el Esclarecimiento de la Verdad, sistema pregunta-respuesta, recuperación aumentada con generación (RAG), grandes modelos de lenguaje, fine-tuning, FAISS, dataset QA, HuggingFace.*

Índice

1. Introducción.....	5
1.1 Planteamiento del Problema.....	5
1.2 Justificación.....	7
1.3 Objetivos.....	8
1.3.1 Objetivo General.....	8
1.3.2 Objetivos Específicos.....	8
1.4 Resultados Obtenidos.....	9
1.5 Alcance.....	10
1.5.1 Límites del Proyecto:.....	10
1.5.2 Aspectos No Abordados:.....	11
2. Marco Referencial.....	12
2.1 Glosario.....	12
2.2 Marco Teórico.....	14
2.2.1 Conflicto Armado en Colombia.....	14
2.2.2 ¿Qué tipo de delitos se cometieron?.....	15
2.2.3 Tensores, Transformers y El Modelo de Atención.....	16
2.2.4 Procesamiento del Lenguaje Natural (PLN) y los LLM.....	17
2.2.5 Los Sistemas de QA, Chatbots y el Fine-tuning de Modelos.....	18
2.2.6 Datasets De Entrenamiento.....	20
2.2.7 Plataforma HuggingFace.....	22
2.3 Antecedentes.....	23
2.3.1 Procesamiento del Lenguaje Natural Por Parte de La Comisión para el Esclarecimiento de la Verdad, la Convivencia y la No repetición (CEV).....	23
2.3.2 Google Gemini - Chatbot con Datos de la Web.....	25
2.3.3 Modelo Entrenado Con Historias Del Conflicto.....	25
2.3.4 Dataset de Pregunta-Respuesta en Español.....	26
2.3.5 Conclusión Antecedentes.....	27
3. Desarrollo.....	29
3.1 Sistema Pregunta-Respuesta y sus Partes.....	29
3.1.1 Pregunta (input del usuario).....	30
3.1.2 Modelo Generativo (LLM).....	31
3.1.3 Embeddings de Documentos.....	31
3.1.4 Buscador de Similitud - FAISS.....	31
3.1.5 Contexto Relevante.....	32
3.1.6 Respuesta Generada.....	32
3.2 Evaluación de Modelos Ligeros para Sistemas de Pregunta-Respuesta.....	33
3.2.1 Modelos Evaluados.....	33
3.2.2 Propósito de las Pruebas.....	34
3.2.3 Metodología.....	34
3.2.4 Resultados.....	35

3.2.4.1 Resultados Observados.....	40
3.2.5 Conclusión.....	41
3.3 Creación del Dataset.....	41
3.3.1 Objetivo y Alcance.....	42
3.3.2 Fuentes y Proceso de Recolección.....	42
3.3.3 Publicación del Dataset en HuggingFace.....	43
3.3.4 Actualización Automática del Dataset.....	44
3.4 Generación de Datos Sintéticos.....	45
3.4.1 Estructura del Dataset y Formatos.....	48
3.4.2 División de conjuntos Train/Test.....	49
3.4.3 Estadísticas Descriptivas.....	49
3.4.4 Licenciamiento y Publicación.....	49
3.4.5 Desafíos y Limitaciones.....	50
3.5 Resultados Obtenidos con los Modelos Propuestos.....	50
3.5.1 Modelos de Lenguaje Entrenados con Datos de La CEV.....	51
3.5.2 Modelos Base Seleccionados.....	54
3.5.2.1 Cuantificación de los Modelos.....	55
3.5.3 Resultados del Entrenamiento.....	59
3.5.3.1 Análisis de Resultados.....	61
3.5.3.2 Consideraciones Éticas y Licenciamiento.....	61
3.5.3.3 Alojamiento y Distribución de Modelos con Ajuste Fino.....	62
3.6 Pruebas Sobre los Modelos con Ajuste Fino.....	63
3.6.1 Análisis de Resultados.....	65
3.7 RAG: Arquitectura General.....	66
3.7.1 Indexado del Corpus.....	67
3.7.2 Recuperación y Generación.....	68
3.7.3 Rendimiento Operativo.....	69
3.7.4 Limitaciones Observadas.....	69
4. Pruebas y Resultados.....	70
4.1 Diseño de la Prueba.....	70
4.1.1 Criterios para la evaluación de respuestas.....	70
4.2 Resultados cuantitativos.....	72
4.3 Resultados Cualitativos.....	75
4.3.1 Análisis de las Respuestas Generadas.....	76
4.4 Límites del Estudio.....	77
4.5 Conclusiones de las Pruebas.....	78
5. Conclusiones y Trabajo Futuro.....	80
5.1 Conclusiones.....	80
5.2 Trabajo Futuro.....	81
6. Bibliografía.....	84
7. Anexos.....	88

1. Introducción

1.1 Planteamiento del Problema

El conflicto armado colombiano, que ha durado más de cinco décadas, dejó un legado de dolor, sufrimiento y miles de víctimas. La Comisión para el Esclarecimiento de la Verdad, la Convivencia y la No Repetición (CEV), creada en el marco del Acuerdo de Paz firmado en 2016, tiene como objetivo esclarecer los hechos y contribuir a la construcción de una paz duradera en el país. Para cumplir con este mandato, la Comisión ha publicado una serie de informes que contienen información valiosa sobre el conflicto, sus actores y las víctimas. Como queda en el Decreto 588 de 2017, artículo 2º, uno de los objetivos de la comisión es contribuir al esclarecimiento de lo ocurrido (Legislación Colombiana, n.d.). Los informes son una herramienta fundamental para cumplir con este objetivo. Son documentos extensos y detallados que sintetizan los hallazgos de la Comisión sobre el conflicto armado. Estos documentos contienen información invaluable para comprender la historia del país y promover la reconciliación. Sin embargo, a pesar de su importancia, existe un desafío significativo: en Colombia, los índices de lectura de libros son bajos, alrededor del 64,0% lee mayoritariamente contenido de redes sociales (DANE, 2017) lo que limita el alcance y el impacto de estos informes en la población general. En contraste, se observa un uso creciente de tecnologías modernas como los chatbots para acceder a información, consultar información preguntando a Chatgpt puede ser hasta un 65.2% más eficiente que buscar en Google (Xu, R. et al., 2023, p.12). Esta realidad plantea la necesidad de adaptar la difusión de estos importantes informes a formatos más accesibles y contemporáneos, como un sistema pregunta-respuesta utilizando interfaces de chat, para facilitar su comprensión y ampliar su alcance entre la ciudadanía.

Existen diversas metodologías para desarrollar sistemas de pregunta-respuesta (QA) con respuestas en lenguaje natural. Sin embargo, crear un sistema QA especializado en un tema específico presenta un desafío significativo. El procesamiento del lenguaje natural (PLN) es un campo de la inteligencia artificial que se dedica al estudio y desarrollo de sistemas que pueden analizar, comprender y generar lenguaje natural de forma automática. Estos sistemas han experimentado un progreso notable en los últimos años, impulsados por el auge de los grandes modelos de lenguaje (LLM) como GPT-3, BERT y Llama. La adopción de tecnologías de inteligencia artificial, como los LLM y el fine-tuning de modelos, presenta una oportunidad para abordar estos desafíos de manera innovadora. Estas tecnologías permiten desarrollar sistemas inteligentes que pueden procesar grandes volúmenes de texto, comprender su contenido y ofrecer respuestas relevantes y contextualmente apropiadas.

Por lo tanto, este trabajo de grado se enfoca en abordar la siguiente pregunta: ¿Cómo puede la aplicación de tecnologías de inteligencia artificial, como los LLM y el fine-tuning de modelos, aportar al desarrollo de un sistema QA que facilite el acceso, comprensión e interacción con la información contenida en los informes de la Comisión Para El Esclarecimiento de La Verdad?

1.2 Justificación

El sistema QA **permite** a los investigadores y estudiantes acceder a información sobre el conflicto armado colombiano y el proceso de paz de manera rápida y eficiente. Esto **facilita** la investigación y el análisis de estos temas. El desarrollo del sistema QA **impulsa** la aplicación de diversos conceptos y técnicas de inteligencia artificial (IA), como el procesamiento del lenguaje natural (PLN) y el aprendizaje automático (ML). El proyecto **contribuye** al avance del conocimiento en estas áreas, ya sea mediante la implementación de nuevas técnicas o la mejora de las existentes. La documentación del proyecto **sirve** como referencia para futuros investigadores que trabajan en el desarrollo de sistemas QA o chatbots.

La implementación de un sistema QA basado en inteligencia artificial **reduce** significativamente el tiempo y los recursos necesarios para acceder y analizar la información contenida en los informes de la CEV. Esto **se traduce** en ahorros de costos tanto para investigadores individuales como para instituciones académicas y organizaciones no gubernamentales que trabajan en temas relacionados con el conflicto armado y la paz.

El resultado final de este proyecto **tiene** un impacto social, ya que **permite** a la sociedad colombiana acceder a información sobre el conflicto armado y el proceso de paz de una forma más rápida y concreta.

1.3 Objetivos

1.3.1 Objetivo General

Desarrollar un sistema de pregunta-respuesta (QA) que facilite el acceso y comprensión de la información contenida en los informes de la CEV sobre el conflicto armado colombiano y el proceso de paz, utilizando tecnologías de inteligencia artificial como los grandes modelos de lenguaje (LLM) y el fine-tuning de modelos.

1.3.2 Objetivos Específicos

1. Desarrollar un dataset anotado para QA con base en la información de los informes de la CEV. Teniendo en cuenta que son alrededor de 700 informes de los que se pueden extraer 3 tipos de preguntas básicas especificadas en la temática del alcance de este proyecto.
2. Implementar las técnicas de ajuste fino (fine-tuning) con el fin de ajustar uno o varios LLM de generación de texto usando un dataset anotado de QA sobre el tema de los informes de La CEV.
3. Publicar el modelo con ajuste fino en HuggingFace para que otros desarrolladores puedan acceder a él, utilizarlo o modificarlo. La plataforma proporciona la infraestructura necesaria para alojar y versionar el modelo, permitiendo así centrarse en su mejora continua.
4. Implementar las medidas de desempeño del modelo resultado del fine-tuning y análisis de resultados.

1.4 Resultados Obtenidos

Tabla 1.

OBJETIVO ESPECÍFICO	RESULTADO O PRODUCTO ESPERADO
1	Se construyó un dataset QA con más de 2800 instancias , generadas a partir de 715 informes oficiales de la CEV. El dataset fue publicado en HuggingFace bajo licencia CC-BY 4.0 .
2	El modelo con mejor desempeño fue Mistral-8B-Instruct-2410-009 (LoRA), seleccionado tras la fase de fine-tuning por obtener la menor <i>validation loss</i> (0.37) y la mayor BERTScore preliminar. En total se ajustaron cinco modelos como se especifica en la sección 3.5.2 .
3	Los checkpoints y adaptadores LoRA de todos los modelos a los que se le hizo ajuste fino se publicaron en la colección de HuggingFace “chatbot-JEP” , acompañados de sus tarjetas de modelo. No se desplegó un endpoint gestionado ni una interfaz gráfica en HuggingFace debido al coste de este servicio.
4	El mejor modelo alcanzó BERTScore 79,36 %, F1 35.85 % y latencia media 6.4s en una GPU A100 (40 GB) como se especifica en la sección 3.6 . Informe con análisis de métricas, arquitectura RAG con FAISS (búsqueda $\approx$ 40s en CPU), más detalle en la sección 3.7.3 .

1.5 Alcance

1.5.1 Límites del Proyecto:

Tipo de sistema QA: Este proyecto se enfoca en el desarrollo de un sistema QA extractivo basado en texto. No se aborda el desarrollo de un sistema QA multimodal que incluya interacción con audio o video.

Temática: El sistema QA se centra en la información contenida en los informes de la Comisión para el Esclarecimiento de la Verdad, la Convivencia y la No Repetición (CEV). Más de 15 informes finales (+500 páginas por informe) y cerca de 700 informes de casos. Se consultan fuentes complementarias confiables, como bases de datos oficiales, artículos académicos y reportes de organizaciones de derechos humanos, para ampliar y contextualizar la información. Los temas que se abordan son los siguientes:

1. Resumen de los hallazgos principales de cada informe.
2. Detalles sobre los casos y eventos específicos documentados en los informes.
3. Análisis de las causas estructurales del conflicto y las recomendaciones para la no repetición.

Población objetivo: El sistema QA está dirigido a investigadores, estudiantes y público en general interesado en el conflicto armado colombiano y el proceso de paz. No se diseña un sistema personalizado para un grupo específico de usuarios con necesidades particulares.

1.5.2 Aspectos No Abordados:

Desarrollo de un chatbot: Si bien el proyecto contempla la creación de una interfaz de chat para el sistema QA, no se desarrolla un chatbot completo con funcionalidades avanzadas como la gestión de diálogos complejos o la personalización de la interacción con el usuario.

Soporte para múltiples idiomas: El sistema QA solo ofrece interacción y soporte en español.

Medición del Impacto Social: No se realiza una medición directa del impacto social del sistema QA. Sin embargo, se anticipa que el proyecto tendrá un impacto social indirecto al facilitar el acceso a información crucial sobre el conflicto armado y el proceso de paz en Colombia, lo cual podría contribuir a la educación y concienciación pública sobre estos temas.

Para concluir el alcance, este proyecto de grado busca desarrollar un sistema QA de calidad que facilite el acceso y la comprensión de la información contenida en los informes de la CEV sobre el conflicto armado colombiano y el proceso de paz, utilizando tecnologías de inteligencia artificial de manera responsable y accesible.

2. Marco Referencial

2.1 Glosario

Chatbot: Un programa informático que simula una conversación con los usuarios (La Web del Programador, n.d.).

Dataset: Colección de datos estructurados y enfocados para una tarea específica (Universidad De Los Andes, 2024).

Fine-tuning: Es un enfoque para transferir el aprendizaje en el que un modelo previamente entrenado se entrena en datos nuevos (Quinn et al., 2019, p. 551).

IA: Inteligencia Artificial.

Lenguaje Natural: La forma de comunicación que utilizan los humanos para interactuar entre sí. Se caracteriza por ser espontáneo, fluido y adaptable.

LLM: Large Language Models, traducido al español como Grandes Modelos de Lenguaje.

ML: Machine Learning, traducido al español como Aprendizaje Automático.

PLN: Procesamiento del Lenguaje Natural.

QA: Question Answering, traducido al español como pregunta-respuesta.

Redes Neuronales Artificiales: Son un campo fascinante de la inteligencia artificial que se inspira en el funcionamiento del cerebro humano (Hardesty, 2017).

2.2 Marco Teórico

En este capítulo se presentan los conceptos básicos relacionados con el diseño y desarrollo de sistemas QA, enfocados en la consulta y análisis de grandes cantidades de datos expresados en lenguaje natural. Particularmente, se abordará la aplicación de estas tecnologías avanzadas en el contexto del conflicto armado en Colombia, basado en los informes de la CEV.

2.2.1 Conflicto Armado en Colombia

Con base al informe final "Hay futuro si hay verdad" (Comisión de la Verdad, 2022) se resumen varios hallazgos que dan contexto sobre el conflicto armado desde sus inicios. El conflicto armado en Colombia, según el informe, se extendió por más de cinco décadas, iniciando aproximadamente en 1964 y prolongandose hasta la firma del Acuerdo de Paz en 2016. Si bien el acuerdo marcó el fin del conflicto formal entre el Estado y las FARC-EP, la violencia y los enfrentamientos armados continúan en algunas regiones del país.

¿Cuántas víctimas hubo?

Determinar un número exacto de víctimas del conflicto armado en Colombia es complejo debido a la naturaleza prolongada y dispersa del mismo. Sin embargo, el informe estima que el conflicto ha dejado un saldo de más de 9 millones de víctimas, incluyendo:

- Más de 220.000 personas asesinadas.
- Más de 75.000 personas desaparecidas.

- Miles de víctimas de violencia sexual.
- Numerosas víctimas de secuestro, reclutamiento forzado y otros crímenes.

2.2.2 ¿Qué tipo de delitos se cometieron?

El informe documenta una amplia gama de graves violaciones a los derechos humanos e infracciones al derecho internacional humanitario durante el conflicto armado, incluyendo:

- Asesinatos extrajudiciales, ejecuciones sumarias y masacres.
- Desapariciones forzadas.
- Desplazamiento forzado.
- Reclutamiento forzado de niños, niñas y adolescentes.
- Violencia sexual.
- Tortura.
- Atentados contra la población civil.
- Crímenes contra pueblos indígenas y afrodescendientes.

¿Quiénes fueron los más afectados?

El informe señala que los grupos más afectados por el conflicto armado fueron:

- Las comunidades rurales y campesinas, especialmente en zonas de alta presencia de grupos armados.
- Los pueblos indígenas y afrodescendientes.
- Las mujeres y las niñas, quienes han sido víctimas de violencia sexual y otras formas de violencia de género.

- Los niños, niñas y adolescentes, quienes han sido reclutados por grupos armados, han sufrido desplazamiento forzado y han sido víctimas de otras graves violaciones a sus derechos.
- Las personas LGBTI.
- Los defensores de derechos humanos y líderes sociales.

Es importante destacar que el informe también reconoce la participación de diversos actores en el conflicto, incluyendo al Estado, los grupos guerrilleros, los paramilitares y las organizaciones criminales. El informe enfatiza la necesidad de un proceso integral de verdad, justicia, reparación y no repetición para garantizar la construcción de una paz duradera en Colombia.


2.2.3 Tensores, Transformers y El Modelo de Atención

Los tensores son estructuras matemáticas de gran relevancia, especialmente en el campo de la inteligencia artificial. Su capacidad para representar datos multidimensionales de manera eficiente los convierte en herramientas esenciales para el desarrollo y entrenamiento de redes neuronales. Estas redes neuronales suelen tener tareas como reconocimiento de imágenes, generación de contenido y toma de decisiones. Los tensores tienen una gran relevancia en los modelos de inteligencia artificial generativos de la actualidad. Es decir, modelos que generan contenido como GPT-3, Midjourney o Stable Diffusion. Por otro lado, los transformers (véase **Figura 1**) son una arquitectura de red neuronal que ha revolucionado el campo del procesamiento del lenguaje natural (PLN) en los últimos años. Introducidos por Google Research en su artículo "Attention is All You Need", los transformers han demostrado un rendimiento superior en una amplia gama de tareas útiles en PLN. A diferencia de las redes neuronales tradicionales, que procesan el texto de manera secuencial, los transformers utilizan un mecanismo de atención que les

permite "atender" a diferentes partes del texto de manera simultánea. Esto les permite capturar relaciones de largo alcance entre las palabras y frases, lo que resulta crucial para comprender el significado del texto (Vaswani et al., 2017).

Figura 1

Arquitectura Transformers



Nota. The Transformer - Model architecture (Vaswani et al., 2017, p. 3) .


2.2.4 Procesamiento del Lenguaje Natural (PLN) y los LLM

El procesamiento del lenguaje natural (PLN) es un campo de la inteligencia artificial que se encarga del estudio y desarrollo de sistemas capaces de analizar, comprender y generar lenguaje natural de manera automática (Nadkarni, P. M & Et al, 2011). Las tecnologías de PLN han experimentado un avance significativo en los últimos años, impulsadas por el auge de los LLM como GPT-3, BERT y Llama.

Los LLM son modelos de aprendizaje automático entrenados en grandes conjuntos de datos de texto. Estos modelos son capaces de aprender las relaciones estadísticas y semánticas entre las palabras y frases, lo que les permite realizar tareas como la traducción automática, la generación de texto y la respuesta a preguntas (Minaee & Mikolov, 2024, p. 1). En la Figura 2 se pueden ver algunas de sus capacidades.

Figura 2

Alcance de los grandes modelos de lenguaje



Nota. LLM Capabilities (Minaee & Mikolov, 2024, p. 2).


2.2.5 Los Sistemas de QA, Chatbots y el Fine-tuning de Modelos

El fine-tuning de modelos es una técnica de aprendizaje automático que consiste en ajustar un modelo pre-entrenado en una tarea específica (Quinn et al. 2019, CAP 14). En el caso de los LLM, el fine-tuning se puede utilizar para optimizar el modelo para responder preguntas sobre un tema específico, como el conflicto armado colombiano y el proceso de

paz (véase Figura 3). Por otro lado, los chatbots son programas informáticos que simulan una conversación con los usuarios. Los chatbots inteligentes utilizan tecnologías de PLN con Inteligencia Artificial y buscan interactuar con los usuarios en distintas tareas siguiendo un flujo de conversación (Kaur et al., 2024, p. 2).


Figura 3

Proceso de ajuste fino de un modelo de lenguaje grande (LLM)



Nota. Resultado de Fine-tuning (Deepset.ai, 2023).

En contraste con lo dicho, un sistema pregunta-respuesta, también conocido como Question Answering (QA), prioriza proporcionar respuestas precisas a preguntas específicas sin necesidad de un diálogo extenso. Los sistemas QA actuales que utilizan grandes modelos de lenguaje (LLM) han revolucionado la forma en que interactuamos con la información. Estos sistemas, a diferencia de los sistemas QA tradicionales basados en reglas específicas para el texto de entrada (Caballero, 2021, p.1 - p.2), aprovechan el poder de los LLM para comprender y responder preguntas de manera más natural, precisa y completa. Un ejemplo de este tipo de sistemas puede verse en la Figura 4, donde se ilustra cómo se realiza la recuperación de contexto relevante a partir de documentos para asistir al modelo en la generación de respuestas.

Figura 4*Esquema de un sistema QA con recuperación de contexto*

Nota. Sistema QA con contexto extraído de documentos (Chase, 2023).

2.2.6 Datasets De Entrenamiento


Un dataset es una colección organizada de datos, que pueden ser números, palabras, imágenes, sonidos, o cualquier otro tipo de información, que se utilizan como entrada para un modelo de aprendizaje automático (H. Renear et al., 2011, p. 2). Un dataset típico consta de una serie de entradas (también llamadas muestras, instancias o ejemplos) que se componen de características o variables, y una etiqueta o respuesta asociada a cada entrada. En el caso de un sistema de pregunta-respuesta o Question Answering (QA), el dataset podría consistir en pares de preguntas y respuestas relacionadas con los informes de la Comisión Para El Esclarecimiento de La Verdad. La calidad y cantidad de los datos en el dataset de entrenamiento son fundamentales para el éxito del fine-tuning del LLM y la precisión del sistema de pregunta-respuesta (Brazdil et al., 2022, p. 55). La Figura 5 ilustra algunos de estos tipos, incluyendo datasets topológicos, de redes, parcelas, entre otros.

Otras características importantes a la hora de elaborar un dataset son:

- **Relevancia:** los datos deben ser relevantes para el problema que se va a resolver.
- **Calidad:** los datos deben ser precisos y consistentes.
- **Cantidad:** la cantidad de datos debe ser suficiente para entrenar un modelo efectivo.
- **Diversidad:** los datos deben ser lo suficientemente diversos para que el modelo generalice bien.
- **Etiquetado:** las etiquetas o respuestas asociadas deben ser precisas y consistentes.

Figura 5

Ejemplos de tipos de datasets en entornos geoespaciales



Nota. Tipos de datasets (ArcGIS, n.d.)

2.2.7 Plataforma HuggingFace

HuggingFace es una plataforma y comunidad de aprendizaje automático que proporciona herramientas y recursos para desarrollar, entrenar, compartir y desplegar modelos de inteligencia artificial. Es conocida por su biblioteca Transformers con soporte para múltiples lenguajes de programación, que ofrece una amplia gama de modelos pre-entrenados y herramientas para tareas de PLN como traducción, resumen, clasificación de texto, y más. HuggingFace proporciona la infraestructura necesaria para desplegar modelos de manera automática. Usando su API Inference, los modelos pueden ser desplegados en servidores gestionados por HuggingFace, permitiendo que se realicen inferencias en tiempo real. (HuggingFace, n.d.)


2.3 Antecedentes

2.3.1 Procesamiento del Lenguaje Natural Por Parte de La Comisión para el Esclarecimiento de la Verdad, la Convivencia y la No repetición (CEV)

La Comisión para el Esclarecimiento de la Verdad, la Convivencia y la No Repetición, establecida como parte del Acuerdo de Paz de 2016, tiene como finalidad esclarecer los hechos y promover una paz duradera en el país. Según el Decreto 588 de 2017, artículo 2º, uno de sus objetivos es aclarar lo sucedido (Legislación Colombiana, n.d.). Por ello, una de sus tareas más arduas ha sido la recopilación de datos, mayormente en lenguaje natural. La **Figura 6** muestra algunos de los proyectos de análisis de lenguaje natural que la Comisión ha desarrollado a partir de esa información.

Figura 6

Ejercicios de análisis de procesamiento de lenguaje natural desarrollados por la CEV




Nota. Proyectos con PLN de la CEV (Comisión De La Verdad, 2022).

2.3.2 Google Gemini - Chatbot con Datos de la Web

Gemini es un LLM desarrollado por Google AI, entrenado en un conjunto de datos masivo de texto y código. Es capaz de realizar una amplia gama de tareas, incluyendo consultar información de cualquier tema. A Gemini se le pueden hacer preguntas generales sobre la CEV. Aunque no tiene conocimiento específico de cada uno de los informes (véase **Figura 9**).

Figura 9

Interacción de Gemini respondiendo preguntas sobre la CEV




Nota. Gemini contestando preguntas sobre La Comisión de La Verdad (Google AI, 2023).

2.3.3 Modelo Entrenado Con Historias Del Conflicto

Un modelo generador de texto entrenado con testimonios del conflicto armado colombiano. Este modelo partió del modelo [GPT-small-spanish](#) al cual se le hizo fine-tuning con un dataset etiquetado de 456 ejemplos de historias del conflicto armado en

Colombia. En la **Figura 10** se muestra la tarjeta del modelo en Hugging Face y el texto que produce a partir de un prompt inicial.


Figura 10



Nota. Modelo generativo gpt2-small-spanish-historias-conflicto-col (Henao, 2022).

2.3.4 Dataset de Pregunta-Respuesta en Español

El dataset SQAC de Plan de Tecnologías del Lenguaje - Gobierno de España (PlanTL-GOB) es un conjunto de datos en español diseñado para evaluar la comprensión de lectura y la capacidad de responder preguntas. Este dataset contiene 6.247 contextos y 18.817 preguntas con sus respectivas respuestas, variando de 1 a 5 preguntas por contexto. Los contextos provienen de diversas fuentes como artículos enciclopédicos de la Wikipedia en español y artículos de noticias de Wikinews (PlanTL-GOB, 2023). **En la Figura 11 se muestra** un ejemplo de las anotaciones que conforman el dataset.

Figura 11*Estructura de pregunta, respuesta y contexto en el dataset SQAC*

Nota: Ejemplo del dataset SQAC. Elaboración propia.

2.3.5 Conclusión Antecedentes

A partir de la revisión de antecedentes, se evidencia que si bien existen diversos proyectos que han aplicado técnicas de procesamiento del lenguaje natural (PLN) a los informes de la CEV, este trabajo de grado se distingue por las siguientes características:

- Enfoque en la construcción de un sistema QA: A diferencia de los proyectos anteriores que se han centrado en el análisis de grandes volúmenes de texto, este trabajo de grado se propone desarrollar un dataset anotado y un sistema QA que permita a los usuarios acceder a información específica de manera rápida y eficiente.
- Utilización de un LLM de última generación: El sistema QA se basa en grandes modelos de lenguaje (LLM) como LLama, lo que permitirá ofrecer una mayor precisión y comprensión del lenguaje natural.

- Fine-tuning del modelo LLM: El LLM se entrena con un conjunto de datos de preguntas y respuestas sobre el conflicto armado colombiano, lo que permite mejorar su rendimiento en esta tarea específica.


En conjunto, este trabajo de grado hace una contribución significativa al facilitar el acceso a la información contenida en los informes de la Comisión para el Esclarecimiento de la Verdad, lo que contribuye a la investigación, el análisis y la comprensión del conflicto armado colombiano y el proceso de paz

3. Desarrollo

3.1 Sistema Pregunta-Respuesta y sus Partes.

Para el desarrollo de este sistema pregunta-respuesta, se utiliza un enfoque RAG (Recuperación Aumentada con Generación), como se ilustra en la **Figura 12**. Este sistema emplea embeddings para mejorar la interacción con los usuarios mediante consultas contextualmente relevantes extraídas de documentos. Los documentos en formato PDF se procesan para extraer su contenido y representarlo como vectores numéricos en un espacio multidimensional mediante técnicas de embeddings. En este flujo, al realizar una consulta, el sistema compara su representación vectorial con los embeddings de los documentos almacenados, seleccionando los fragmentos de texto más cercanos en el espacio vectorial. Estos fragmentos recuperados son enviados a un modelo generador, como un LLM, que produce una respuesta contextual y precisa basada en la información encontrada. Este diseño permite que el sistema entregue respuestas específicas y pertinentes, incluso frente a algunas preguntas complejas o altamente contextualizadas..

Para este proyecto, se utilizó FAISS (Facebook AI Similarity Search) como el buscador principal de fragmentos. El fragmento encontrado por FAISS sirve como el contexto que alimenta el modelo con fine-tuning, el cual se encarga de elaborar la respuesta a cada pregunta.

Figura 12*Sistema pregunta respuesta desarrollado*

3.1.1 Pregunta (input del usuario)

Descripción: Es el punto de partida del flujo del sistema. El usuario formula una pregunta en lenguaje natural sobre el tema específico, en este caso, el conflicto armado colombiano y los informes de La CEV.

Función: Esta pregunta se convierte en una consulta que será procesada por el sistema. El objetivo es que la pregunta sea lo suficientemente clara para identificar la información relevante en los documentos almacenados.

3.1.2 Modelo Generativo (LLM)

Descripción: Un modelo de lenguaje de última generación (LLM) como Mistral, BERT o LLaMA que ha sido ajustado mediante técnicas de fine-tuning para entender preguntas y responderlas en el contexto del conflicto armado.

Función: Recibe el fragmento recuperado y lo usa para generar una respuesta en lenguaje natural que sea precisa, relevante y coherente con la consulta del usuario.

3.1.3 Embeddings de Documentos

Descripción: Los documentos (por ejemplo, en formato PDF) son preprocesados, extrayendo su contenido textual y dividiéndolo en fragmentos manejables (chunks). Cada uno de estos fragmentos de texto es transformado en un **vector numérico denso**, conocido como *embedding*, utilizando modelos de lenguaje avanzados (como BERT, OpenAI Embeddings, etc.). Estos embeddings representan semánticamente el contenido del fragmento en un espacio de alta dimensión, donde la proximidad entre vectores indica una similitud de significado.

Función: Esta representación permite al sistema comparar la similitud entre la consulta del usuario y los contenidos de los documentos. Los embeddings son fundamentales para identificar las partes más relevantes del texto.

3.1.4 Buscador de Similitud - FAISS

Descripción: Este componente es la **funcionalidad operativa** que consulta un **índice FAISS pre-construido** (el cual contiene los embeddings vectoriales de los

documentos). Su rol es tomar el **embedding de la pregunta del usuario** y utilizarlo para interactuar con dicho índice, midiendo la similitud entre la consulta y los embeddings de documentos almacenados.

Función: La misión del Buscador de Similitud es identificar y recuperar de forma **altamente eficiente y en tiempo real** los **k fragmentos de texto más relevantes** que se alinean semánticamente con la pregunta del usuario. Para lograr esto, invoca y utiliza los **algoritmos optimizados de búsqueda de vecinos más cercanos aproximados (ANN)** que FAISS ofrece (Douze et al., 2024) .

3.1.5 Contexto Relevante

Descripción: Son los fragmentos de texto encontrados por el buscador de similitud.

Función: Este componente es crucial para **limitar la información** que se envía al modelo generativo. Su propósito es integrarse en el prompt que se le pasa al modelo generativo, lo que permite generar una respuesta precisa y evitar procesar información innecesaria.

3.1.6 Respuesta Generada

Descripción: Es el resultado final del sistema. La respuesta es entregada al usuario en un formato comprensible y directo.

Función: Proporciona información específica basada en la pregunta del usuario y el contexto relevante encontrado en los documentos.

3.2 Evaluación de Modelos Ligeros para Sistemas de Pregunta-Respuesta

En el marco del desarrollo de un sistema de pregunta-respuesta (QA) basado en los informes de La CEV sobre el conflicto armado colombiano, se realizaron pruebas con distintos modelos de lenguaje pre-entrenados. El objetivo no fue determinar cuál de ellos es superior, sino explorar cómo modelos de distintas escalas —especialmente los más livianos— pueden ser útiles para tareas de recuperación de información y generación de respuestas coherentes y contextualmente apropiadas.

3.2.1 Modelos Evaluados

Gemma2-9b: Con 9 mil millones de parámetros, Gemma2-9b representa un modelo de gran escala diseñado para equilibrar potencia y eficiencia. Fue incluido en las pruebas como un referente de alto rendimiento, con capacidades avanzadas para comprender consultas complejas y generar respuestas precisas a partir de información semántica densa (Team et al., 2024).

TinyLlama-1b: Este modelo, con apenas 1 mil millones de parámetros, fue incorporado con el propósito específico de examinar el rendimiento de una arquitectura liviana. Pese a sus limitaciones en capacidad, puede ofrecer respuestas razonables y útiles en escenarios con restricciones de hardware (Zhang et al., 2024).

Llama3.1-8b: Llama3.1-8b, con 8 mil millones de parámetros, se probó como un punto medio entre modelos grandes y ligeros. Presenta mejoras en comprensión contextual y eficiencia, lo que lo convierte en un candidato ideal para tareas que requieren equilibrio entre profundidad en las respuestas y velocidad de inferencia (Grattafiori et al., 2024, p. 20).

3.2.2 Propósito de las Pruebas

Estas evaluaciones no tuvieron como finalidad seleccionar un modelo “óptimo”, sino comprobar que incluso modelos reducidos pueden ser funcionales en un entorno QA, siempre y cuando se estructure adecuadamente el sistema. En particular, se buscó verificar que los modelos ligeros son capaces de identificar informes relevantes y generar respuestas coherentes sin necesidad de infraestructura de alto costo.

3.2.3 Metodología

Para todos los modelos se aplicó el mismo procedimiento:

- **Generación de embeddings** del listado de informes el cual contiene título y descripción de cada informe (Informes y casos, 2022).
- **Formulación de consultas** en lenguaje natural.
- **Evaluación cualitativa** de las respuestas generadas, observando su coherencia, precisión y relevancia. Las respuestas generadas se presentan en las **figuras 13–18**


3.2.4 Resultados

Gemma2-9b:

El modelo recupera con precisión tres informes específicos —identificados por su código catálogo— que abordan violencia sexual en distintos territorios; demuestra capacidad para filtrar por tema y entregar referencias verificables, aunque se limita a enumerar títulos sin profundizar en hallazgos ni en la magnitud del corpus disponible (véase Figura 13).

Figura 13

Pregunta sobre informes de violencia contra las mujeres en el conflicto armado




Nota: respuesta generada por Gemma2-9b a la consulta "¿hay algún informe que hable sobre la violencia hacia la mujer...?"

La respuesta ofrece dos informes que vinculan narcotráfico y conflicto (uno nacional y otro focalizado en Bolívar), evidenciando pertinencia temática y consistencia en el formato de citación; sin embargo, la brevedad sugiere que el modelo prioriza ejemplos directos sobre un listado exhaustivo, dejando espacio para ampliar el análisis con síntesis de contenido o más referencias (véase Figura 14).

Figura 14

Pregunta sobre informes del impacto del narcotráfico en la dinámica del conflicto armado




Nota: respuesta generada por Gemma2-9b a la consulta sobre el impacto del narcotráfico en la dinámica del conflicto armado.

Tinyllama-1b:

TinyLlama-1b recupera dos informes concretos que analizan cómo el narcotráfico incidió en la configuración de actores armados, uno a escala nacional y otro situado en Bolívar; muestra pertinencia temática y cita códigos de catálogo, aunque la respuesta es breve y no cuantifica la amplitud del corpus (véase Figura 15).

Figura 15

Pregunta sobre informes del impacto del narcotráfico en la dinámica del conflicto armado




Nota. Respuesta generada por TinyLlama-1b a la consulta "¿Existe algún informe sobre cuál fue el impacto del narcotráfico en la dinámica del conflicto armado?"

Frente a la pregunta sobre violencia contra las mujeres, el modelo identifica tres informes que documentan violencia sexual en Norte de Santander, Nariño y a nivel nacional; evidencia capacidad para filtrar por género y conflicto, y aporta referencias trazables, aunque sin resumir hallazgos ni estimar cuántos documentos adicionales existen (véase **Figura 16**).

Figura 16


Pregunta sobre informes de violencia contra las mujeres en el conflicto armado



Nota. Respuesta generada por TinyLlama-1b a la consulta "¿hay algún informe que hable sobre la violencia hacia la mujer en el conflicto?".

Llama3.1-9b:

Llama 3.1-9b identifica tres informes sobre violencia sexual contra mujeres —incluidos los códigos de catálogo— y añade detalles cuantitativos (21 víctimas, 479 casos) junto con una explicación sucinta de la dinámica de género, lo que muestra mayor contextualización que los modelos precedentes (véase Figura 17).


Figura 17*Pregunta sobre informes de violencia contra las mujeres en el conflicto armado*

Nota. Respuesta generada por Llama 3.1-9b a la consulta "¿hay algún informe que hable sobre la violencia hacia la mujer en el conflicto?"

Ante la consulta sobre narcotráfico, el modelo recupera tres informes que relacionan economía ilícita, paramilitarismo y consolidación de grupos armados, aportando síntesis temáticas que clarifican cómo el narcotráfico profundizó el conflicto y ofreciendo una visión más rica que la simple enumeración de títulos (véase **Figura 18**).

Figura 18

Pregunta sobre informes del impacto del narcotráfico en la dinámica del conflicto armado



Nota. Respuesta generada por Llama 3.1-9b a la consulta "¿Existe algún informe sobre cuál fue el impacto del narcotráfico en la dinámica del conflicto armado?".

3.2.4.1 Resultados Observados

- **Gemma 2-9b.** Para ambas consultas recuperó referencias idóneas (tres informes sobre violencia sexual y dos sobre narcotráfico) con sus códigos de catálogo. Las respuestas son precisas y claras, pero muy concisas: se limitan a enumerar títulos sin sintetizar hallazgos ni estimar la amplitud del corpus.
- **TinyLlama-1b.** Aun con sólo 1 B de parámetros igualó la precisión de Gemma (dos informes sobre narcotráfico y tres sobre violencia sexual), lo que confirma su viabilidad en entornos de recursos limitados. Sin embargo, mantiene el mismo patrón de brevedad y carece de detalles cuantitativos o interpretativos.

- **Llama 3.1-9b.** Conserva la exactitud en la recuperación de fuentes, pero añade contexto: incluye cifras de víctimas, explica la influencia de género y describe la relación entre narcotráfico, paramilitarismo y economía ilícita. Esa información extra aporta la contextualización más rica de los tres modelos y resulta valiosa para consultas que demandan mayor profundidad.

3.2.5 Conclusión

Las pruebas permitieron evidenciar que los modelos ligeros como TinyLlama-1b no solo son viables, sino que representan una alternativa práctica para implementar sistemas QA eficientes en entornos con recursos limitados. Este hallazgo es relevante para el desarrollo de soluciones accesibles que permitan democratizar el acceso a información compleja como la contenida en los informes del conflicto armado colombiano.

3.3 Creación del Dataset


3.3.1 Objetivo y Alcance

El propósito de este corpus es proveer al modelo que se entrene con una base de conocimiento sobre el conflicto armado colombiano. Para ello se trabajó con **los 715 informes públicos disponibles** en el portal de La CEV a la fecha de recolección. No se aplicó ninguna clasificación temática previa; la intención fue capturar la totalidad de los hallazgos, conclusiones y evidencias consignadas por la CEV.

3.3.2 Fuentes y Proceso de Recolección

La obtención de los documentos se llevó a cabo mediante *scraping* automatizado con **Selenium** (librería de python) en el sitio oficial de la CEV.

Para obtener los informes de La CEV sobre el conflicto armado colombiano, se utilizó un script basado en Selenium que recorrió el listado de informes (véase **Figura 19**) . La CEV proporciona de manera pública un listado de informes junto con su Nombre, descripción y URL para acceder al archivo (Informes y casos, 2022). Se inició la descarga de los archivos y los almacenó directamente en una carpeta de Google Drive, sin conversiones ni pasos de normalización como se muestra en la **Figura 20**. Cada informe fue nombrado utilizando el identificador oficial asignado por la CEV (ej. 058-CI-00233) para mantener una referencia única y ordenada. Algunos documentos no pudieron ser descargados debido a que el archivo no se encontraba disponible o no estaba en el formato adecuado (PDF o CSV).
Volumen bruto: 702 documentos.

Figura 19*Flujo descarga de documentos***Figura 20***Archivos guardados en carpeta drive*

Name ↓	Owner	Last modified ▼	File size	
1376-CI-02086.pdf	juan.david.tovar	Aug 17, 2024 juan.david.tovar	7.7 MB	
1376-CI-02066.pdf	juan.david.tovar	Aug 17, 2024 juan.david.tovar	26 KB	
1376-CI-02065.pdf	juan.david.tovar	Aug 17, 2024 juan.david.tovar	373 KB	
1308-CI-02056.pdf	juan.david.tovar	Aug 17, 2024 juan.david.tovar	8.5 MB	
1308-CI-02049.pdf	juan.david.tovar	Aug 17, 2024 juan.david.tovar	4.9 MB	
1308-CI-02043.pdf	juan.david.tovar	Aug 17, 2024 juan.david.tovar	4.7 MB	
1308-CI-02034.pdf	juan.david.tovar	Aug 17, 2024 juan.david.tovar	134.7 MB	
1308-CI-02031.pdf	juan.david.tovar	Aug 17, 2024 juan.david.tovar	74.5 MB	
1308-CI-02024.pdf	juan.david.tovar	Aug 17, 2024 juan.david.tovar	210.2 MB	
1308-CI-02022.pdf	juan.david.tovar	Aug 17, 2024 juan.david.tovar	112.5 MB	

3.3.3 Publicación del Dataset en HuggingFace


El dataset se carga en HuggingFace utilizando su API de Datasets, lo que permite gestionar el dataset de manera centralizada y aprovechar las herramientas de visualización y análisis que ofrece la plataforma. Esto también facilita la reutilización del dataset para otros grandes modelos de lenguaje (LLM) en tareas de pregunta-respuesta.

3.3.4 Actualización Automática del Dataset

Para garantizar que el dataset se mantenga actualizado conforme se agregan nuevos informes de la CEV, se implementó el flujo mostrado en la Figura 21.

Figura 21

Generacion de dataset sintetico



Generación Automática de Entradas: A través de un modelo de soporte o un pipeline basado en PLN, se generan automáticamente nuevas preguntas y respuestas iniciales para los informes recién agregados.

Sincronización con HuggingFace: Se utiliza la API de HuggingFace para actualizar el dataset directamente desde el script. El script agrega las nuevas entradas al dataset

alojado en HuggingFace sin necesidad de intervención manual. Esto asegura que cualquier modelo o proyecto que utilice este dataset tenga acceso a la versión más reciente.

Versionamiento: Cada actualización crea una nueva versión del dataset en HuggingFace, permitiendo mantener un historial completo de cambios. Esto es útil para evaluar el impacto de nuevas entradas en el rendimiento del modelo y garantizar trazabilidad.

3.4 Generación de Datos Sintéticos

Con el fin de incrementar la diversidad de pares *pregunta-respuesta* y reducir el esfuerzo de anotación manual, se generaron instancias sintéticas sobre 680 documentos que corresponde a el **95 % de los informes listados por La CEV** y el 5% restante fueron descartados porque no es posible extraer el texto del archivo debido a su formato. El procedimiento fue el siguiente:

- **LLM empleado:** GPT-4o y GPT-4.1 vía API. Estos modelos representan las versiones más avanzadas de OpenAI lanzadas en 2025, destacando por su capacidad para procesar y resumir información de grandes volúmenes de texto (Introducing GPT-4.1 in the API, 2025). Inicialmente, se generaron instancias sintéticas exclusivamente con GPT-4o debido a su alto rendimiento. Posteriormente, se incorporó GPT-4.1 para aprovechar su costo reducido en la API de OpenAI (de pago), optimizando así el balance entre calidad y gasto computacional
- Plantilla de *prompt*:
 1. *Hallazgos principales.*

«Tienes acceso al texto completo de {{report_name}}».

Tu tarea es crear una instancia de entrenamiento para un sistema de pregunta-respuesta (QA) sobre el conflicto armado en Colombia.

La pregunta (question) será: «¿Cuáles son los hallazgos principales del informe {{report_name}} sobre el conflicto armado colombiano?»

El campo context debe incluir el fragmento relevante del informe que permita justificar la respuesta.

El campo answer debe ser un resumen conciso de dichos hallazgos, usando un lenguaje acorde con las fuentes oficiales y empleando términos apropiados.

Si el informe no proporciona información relevante entonces no generes contexto (déjalo vacío) en la respuesta pones "No tengo contexto para contestar esa pregunta".

Devuélveme el resultado final en un formato JSON con estas claves: question, context, answer.».

2. *Conclusiones principales.* Idem al punto anterior, sustituyendo «hallazgos» por «conclusiones».

3. *Pregunta de búsqueda.*

*«Imagina que el usuario busca este informe. Formula una pregunta que requiere como respuesta el **nombre oficial** y el **ID** del informe».*

4. Instancia de control (out-of-scope).

«Genera un par QA donde la pregunta sea claramente ajena al conflicto armado colombiano (p. ej., “¿Cuál es la capital de Francia?”) y la respuesta sea exactamente: “Lo siento, solo puedo responder preguntas relacionadas con el conflicto armado colombiano.”».

Ejemplos del prompt aplicado y la respuesta generada en la tabla 2-3.

Tabla 2

Ejemplo de contexto y respuesta generados por un LLM

Atributo	Valor
Pregunta	¿Cuáles son los hallazgos principales del informe 058-CI-00233 Informe agroarte Colombia: Red Territorial de la Memoria sobre el conflicto armado colombiano?
Contexto	Los argumentos conforme a los que estimamos necesario realizar actuaciones efectivas destinadas al reconocimiento y la protección de los lugares memoriales generados por la interacción de víctimas y colectivos sociales en los territorios entroncan con dos elementos esenciales de la realidad colombiana actual: - El valor de estos espacios para la consecución de una paz estable y duradera por el papel que potencialmente les corresponde en la construcción de memorias e identidades locales, - La ausencia, en el ordenamiento jurídico colombiano, de fórmulas articuladas que sean útiles para la defensa de su pervivencia en el tiempo.
Respuesta	El informe destaca la importancia de los espacios de memoria para construir una paz duradera en Colombia, subrayando su papel en la creación de memorias e identidades locales. Además, identifica la falta de un marco jurídico adecuado para proteger estos lugares, lo que amenaza su continuidad y su capacidad para contribuir a la reconciliación y la no repetición del conflicto
Generado por	gpt-4o

Tabla 3

Ejemplo de pregunta de control con contexto y respuesta generados por un LLM

Atributo	Valor
Pregunta	¿Cuántos kilómetros hay entre Bogotá y París en línea recta?
Contexto	
Respuesta	Lo siento, solo puedo responder preguntas relacionadas con el conflicto armado colombiano
Generado por	gpt-4o

Tasa de generación de 3 instancias por documento + Instancias de control $\approx$ 2800 instancias QA. **Campo “Generado por”**: se añade la cadena "gpt-4o" o "gpt-4.1" .

3.4.1 Estructura del Dataset y Formatos.

El dataset se publica en formatos **JSON** y **Parquet** compatibles con *HuggingFace Datasets*. Los campos de cada registro se encuentran explicados en la tabla 4.

Tabla 4

Campo	Descripción
context	Fragmento textual ($\leq$ 1 024 tokens) que fundamenta la respuesta.
question	Enunciado interrogativo, 50-80 tokens, en español.
answer	Respuesta canónica extraída o generada.
generated_by	Identificador del modelo LLM que creó la instancia.

3.4.2 División de conjuntos Train/Test

- Se alojaron en el dataset de HuggingFace todas las instancias, distribuidas en dos conjuntos de datos: 90 % para entrenamiento (train) y 10 % para prueba (test).

3.4.3 Estadísticas Descriptivas

En la tabla 5 se muestran las métricas principales obtenidas de los registros generados.

Tabla 5

Características del dataset sintético

Métrica	Valor
Nº total de informes	680
Nº pares QA sintéticos	≈ 2800
Longitud media de las preguntas	50 tokens
Longitud media de las respuestas	100 tokens
Longitud media de contexto	135 tokens

3.4.4 Licenciamiento y Publicación

El dataset se liberará en *HuggingFace Hub* con id único `jdavit/colombia-conflict-SQA`.

Bajo la licencia **Creative Commons Attribution 4.0 International (CC BY 4.0)**. Esta

licencia permite usar, distribuir y adaptar el recurso —incluso con fines comerciales— siempre que se cite adecuadamente la fuente original.

3.4.5 Desafíos y Limitaciones

- **Ruido y reconocimiento óptico de caracteres (OCR):** Los modelos de lenguaje como GPT-4o no pueden procesar directamente texto contenido en PDFs sin OCR, ya que estos archivos son tratados como simples imágenes o contenedores sin capa de texto legible. Cuando un PDF se genera a partir de una foto o escaneo sin OCR, el contenido es visual (píxeles), no datos textuales. Las APIs de OpenAI no tiene capacidad nativa para extraer texto de archivos generados a partir de documentos escaneados o imágenes, a menos que se integre con herramientas externas de OCR.
- **Ausencia de control temático:** Dado que el objetivo de este dataset es solo dar una base de conocimiento al modelo que se le hará ajuste fino, la falta de etiquetas dificulta análisis estratificados posteriores.
- **Sesgos:** las instancias reflejan la perspectiva editorial de La CEV y las heurísticas de GPT-4o y GPT-4.1.

3.5 Resultados Obtenidos con los Modelos Propuestos

En este apartado se exponen los **resultados cuantitativos** obtenidos tras evaluar los modelos de lenguaje que fueron entrenados con el dataset **colombian-conflict-SQA** que se construyó y publicó anteriormente. El análisis se concentra exclusivamente en el **desempeño intrínseco** de dichos modelos luego del proceso de *fine-tuning*.

3.5.1 Modelos de Lenguaje Entrenados con Datos de La CEV

Los modelos de lenguaje de código abierto utilizados compartieron la misma configuración de entrenamiento y cuantificación, con el objetivo de mantener la coherencia en la comparación de resultados. Esta parametrización fue cuidadosamente definida considerando tanto las limitaciones de hardware (particularmente de VRAM) como la estabilidad del entrenamiento. A continuación, se describen los principales parámetros utilizados en la estructura de la Figura 22.

Figura 22

Parámetros de entrenamiento

```
training_args = TrainingArguments(
    output_dir="./Chatbot-JEP/Ministral-8B-Instruct-2410-JEP",
    per_device_train_batch_size=1,
    gradient_accumulation_steps=4,
    learning_rate=2e-5,
    num_train_epochs=10,
    logging_dir="./logs",
    logging_steps=10,
    eval_strategy="steps",
    eval_steps=100,
    save_strategy="steps",
    save_steps=100,
    fp16=True,
    gradient_checkpointing=True,
    optim="paged_adamw_8bit",
    report_to=["tensorboard"],
    load_best_model_at_end=True,
    remove_unused_columns=False,
    push_to_hub=True
)
```

- **Tamaño del batch para entrenamiento (train_batch_size): 1**

Esto significa que el modelo procesa 1 ejemplo (pregunta-respuesta) por paso de entrenamiento. Este valor fue seleccionado debido a las restricciones de memoria VRAM, optimizando el uso de los recursos disponibles sin comprometer la calidad del ajuste.

- **Pasos de acumulación del gradiente (gradient_accumulation_steps): 4**

Dado que el modelo entrena con un batch de tamaño 1, se acumulan los gradientes durante 4 pasos antes de actualizar los pesos, lo que da como resultado un batch efectivo de 4 (1×4). Esta técnica permite simular un entrenamiento con batches más grandes sin exceder los límites de VRAM, aunque a costa de un tiempo de entrenamiento más prolongado.

- **Tasa de aprendizaje (learning_rate): 0.00002**

Se utilizó una tasa de aprendizaje baja para evitar el sobreajuste y mejorar la estabilidad del proceso de ajuste fino. Este valor resulta especialmente útil en combinación con técnicas de cuantificación como QLoRA, las cuales requieren una tasa de cambio controlada para preservar la precisión del modelo.

- **Cuantificación y ajuste fino**

Algunos modelos fueron cuantificados utilizando QLoRA, lo cual permite reducir el uso de VRAM durante el entrenamiento, limitando la actualización a capas específicas del modelo. Esta técnica es especialmente relevante en modelos (7B y 8B), que pueden superar los 24 GB de VRAM sin cuantificación.

- **Tamaño total de batch de entrenamiento (total_train_batch_size): 4**

Este valor se deriva del tamaño del batch de entrenamiento y los pasos de acumulación de gradientes, lo que da como resultado un batch efectivo de 4.

- **Optimizador (optimizer): AdamW**

AdamW es un optimizador adaptativo que ajusta los pesos del modelo durante el entrenamiento. Los valores de betas y epsilon son comunes y ayudan a controlar el comportamiento de las actualizaciones de pesos, mejorando la convergencia y la regularización para evitar el sobreajuste.

- **Scheduler de tasa de aprendizaje (lr_scheduler_type): Lineal**

El tipo de *scheduler* lineal ajusta la tasa de aprendizaje de manera lineal durante el entrenamiento, permitiendo un control más fino a medida que el modelo avanza hacia la convergencia, evitando cambios bruscos en los parámetros que podrían afectar negativamente la estabilidad del entrenamiento.

- **Número de épocas (num_epochs): 10**

El número de épocas indica cuántas veces el modelo pasará por todo el conjunto de datos durante el entrenamiento. En este caso, se ha establecido un valor de 10 para asegurar que el modelo tenga suficientes oportunidades para aprender de los datos sin correr el riesgo de sobreajuste.

- **Entrenamiento en precisión mixta (mixed_precision_training): Native AMP (Precisión Mixta Nativa)**

La precisión mixta permite al modelo utilizar precisión de 16 bits durante los cálculos. Esto reduce el uso de memoria y acelera el entrenamiento, permitiendo la optimización de modelos más grandes sin sacrificar la precisión.

Esta configuración conjunta permitió realizar el entrenamiento de modelos grandes en hardware con recursos limitados, manteniendo un equilibrio entre rendimiento, tiempo de entrenamiento y estabilidad en las métricas obtenidas. Toda ésta configuración tuvo que ser cuantificada para que fuese entrenable.

3.5.2 Modelos Base Seleccionados

En la **tabla 6** se presenta el nombre del modelo base seleccionado y su respectivo ID en la plataforma HuggingFace.

Tabla 6

Modelos base para ajuste fino

Modelo base	Tamaño aproximado	Licencia	Repositorio / ID HF
Mistral-7B-Instruct-v0.3	7000 M	Apache-2.0	mistralai/Mistral-7B-Instruct-v0.3
Mistral-8B-Instruct-2410-009	8000 M	Apache-2.0	mistralai/Mistral-8B-Instruct-2410
Llama-3.2-3B-Instruct	3000 M	Llama-3.2 license	meta-llama/Llama-3.2-3B-Instruct
Llama-2-7B-Nous-Hermes	7000 M	MIT	NousResearch/Nous-Hermes-llama-2-7b
OpenHermes-2.5-Mistral-7B	7000 M	Apache-2.0	teknium/OpenHermes-2.5-Mistral-7B

Todos los modelos se seleccionaron por ser **ligeros (< 10 B parámetros)** y **recientes**, con reportes públicos positivos para tareas en español, lo que favorece costos y tiempos de entrenamiento manejables.

3.5.2.1 Cuantificación de los Modelos

La cuantificación es una técnica fundamental para reducir el uso de memoria VRAM en la GPU durante la ejecución y el ajuste fino de grandes modelos de lenguaje. En estos entrenamientos, se aplicó cuantificación con el objetivo de ajustar modelos de 7 mil, 8 mil y 9 mil millones parámetros en GPUs con 24 GB de VRAM, algo que resultaría inviable sin esta optimización.

Para el proceso de ajuste fino se utilizó el enfoque PEFT (Parameter-Efficient Fine-Tuning, en español, Afinamiento Eficiente de Parámetros), que consiste en mantener congelados los pesos del modelo pre entrenado y añadir un conjunto reducido de parámetros entrenables. De este modo, en lugar de ajustar todos los millones (o miles de millones) de parámetros del modelo, solo se entrena una pequeña fracción, lo que reduce significativamente el consumo de recursos computacionales. Entre las técnicas PEFT disponibles, se empleó LoRA (Low-Rank Adaptation), que introduce matrices de bajo rango en capas específicas del modelo, permitiendo adaptar su comportamiento sin modificar directamente los pesos originales. LoRA ha demostrado ser especialmente eficiente para tareas de ajuste fino en entornos con recursos de hardware limitados. Además, para reducir aún más el uso de memoria VRAM, se aplicó QLoRA (Quantized LoRA), una variante que combina LoRA con cuantificación a 4 bits. Esta técnica permite trabajar con modelos de gran tamaño utilizando una fracción del requerimiento de memoria habitual (Xu, L. et al., 2023). La Figura 23 presenta la configuración de cuantificación a 4 bits utilizada para cada modelo.

Figura 23

Cuantificación utilizada

```
# Configuración de cuantización 4-bit
bnb_config = BitsAndBytesConfig(
    load_in_4bit=True,
    bnb_4bit_use_double_quant=True,
    bnb_4bit_quant_type="nf4",
    bnb_4bit_compute_dtype=torch.float16
)
```

Lo primero a considerar en el proceso de cuantificación es el uso de la librería BitsAndBytes, una herramienta de código abierto diseñada para optimizar el uso de memoria y el rendimiento de modelos de lenguaje de gran tamaño (LLMs), especialmente en entornos con recursos de VRAM limitados. Esta herramienta permite reducir el tamaño del modelo hasta en un 75 %, al pasar de una representación de 32 bits a solo 4 bits por peso. Los principales componentes utilizados tienen las siguientes funciones:

- `load_in_4bit=True`: indica que el modelo debe cargarse utilizando una representación de 4 bits por peso, en lugar de los 32 o 16 bits originales.
- `bnb_4bit_use_double_quant=True`: activa la doble cuantificación, lo que permite reducir aún más el uso de memoria VRAM.
- `bnb_4bit_quant_type="nf4"`: especifica el uso del esquema de cuantificación nf4 (normal float 4), diseñado para ajustarse a la distribución estadística típica de los pesos en redes neuronales pre entrenadas, logrando mayor eficiencia sin pérdida significativa de precisión.

- `bnb_4bit_compute_dtype=torch.float16`: define que las operaciones internas se realicen en precisión de 16 bits (float16), a pesar de que los pesos estén cuantificados en 4 bits. Es fundamental establecer este parámetro para evitar que las operaciones se ejecuten por defecto en float32, lo cual incrementaría el uso de memoria.

La Figura 24 muestra el proceso de cuantificación del modelo de lenguaje, como paso previo a su ajuste fino utilizando la combinación de PEFT + LoRA.

Figura 24

Proceso de cuantificación del modelo de lenguaje

```
model = AutoModelForCausalLM.from_pretrained(  
    model_name,  
    quantization_config=bnb_config,  
    device_map="auto",  
    torch_dtype=torch.float16  
)
```

La variable `model_name` indica el modelo de lenguaje utilizado en el entrenamiento hecho por cada modelo, entre los cuales se incluyeron Mistral-7B, Llama-3-8B y Llama-2-3B, entre otros. Por su parte, `quantization_config=bnb_config` permite incorporar la configuración de cuantificación a 4 bits mediante la librería BitsAndBytes. La variable `device_map="auto"` activa una funcionalidad de HuggingFace que distribuye automáticamente el modelo entre las GPUs disponibles. En este caso, el modelo fue cargado por completo en una única GPU, la misma que se utilizó para el proceso de ajuste fino. A su vez, `torch_dtype=torch.float16` fuerza la ejecución de las operaciones internas en punto flotante de 16 bits (float16), lo cual resulta fundamental para reducir el uso de memoria sin afectar significativamente el rendimiento del modelo.

La Figura 25 muestra la aplicación de LoRA ya combinada con la cuantificación de QLoRA (Quantized LoRA). En este enfoque, LoRA configura el modelo transformer enfocándose en capas específicas, insertando adaptadores de bajo rango que permiten el ajuste fino eficiente. Para convertir un modelo pre entrenado en un modelo ajustable con QLoRA y reducir al máximo el uso de VRAM, se siguen los siguientes pasos:

1. Cuantificar el modelo base utilizando BitsAndBytesConfig (ver Figura 24).
2. Aplicar LoRA sobre el modelo ya cuantificado (ver Figura 25).

Figura 25

Configuración Lora

```
# Configuración LoRA
peft_config = LoraConfig(
    r=8,
    lora_alpha=32,
    target_modules=["q_proj", "k_proj", "v_proj", "o_proj"],
    lora_dropout=0.05,
    bias="none",
    task_type="CAUSAL_LM"
)
model = get_peft_model(model, peft_config)
model.print_trainable_parameters()
```



La técnica PEFT se aplica mediante la instrucción `model = get_peft_model(model, peft_config)`, donde `model` corresponde al modelo previamente cuantificado y `peft_config` contiene la configuración de los adaptadores LoRA. La variable `r=8` define el rango de las matrices de bajo rango utilizadas; un mayor valor de `r` implica más parámetros entrenables, lo que incrementa la capacidad de adaptación del modelo. Estas matrices adaptadoras se suman al tensor original del modelo, permitiendo modificar su comportamiento sin alterar sus pesos base. El parámetro `lora_alpha=32` actúa como un factor de escalamiento para los

valores aprendidos por las matrices de LoRA, facilitando su integración con los pesos originales. En `target_modules=["q_proj", "k_proj", "v_proj", "o_proj"]` se especifican los módulos del transformer donde se insertan los adaptadores, centrando la intervención en las proyecciones clave del mecanismo de atención (consulta, clave, valor y salida), esenciales para mantener la capacidad de generalización del modelo base.

Finalmente, los parámetros `lora_dropout=0.05`, `bias="none"` y `task_type="CAUSAL_LM"` permiten controlar el ajuste fino: `lora_dropout` introduce regularización para evitar el sobreajuste, `bias="none"` indica que no se modifican los sesgos del modelo original, y `task_type="CAUSAL_LM"` señala que la tarea objetivo es el modelado de lenguaje causal.

3.5.3 Resultados del Entrenamiento

Todos los modelos listados incorporan la **GPU RTX 4090**, la cual viene equipada con **24 GB de VRAM**. En la Figura 26-27 se muestran las curvas de aprendizaje que comparan la evolución de las funciones de pérdida durante el proceso de entrenamiento de los cinco modelos con ajuste fino. Este análisis visual facilita la evaluación de dos aspectos fundamentales: la capacidad de los modelos para aprender patrones a partir de los datos de entrenamiento y su habilidad para generalizar ese conocimiento a datos no vistos previamente. Las curvas ofrecen evidencia directa de posibles problemas de sobreajuste (cuando el Training Loss es significativamente menor que el Validation Loss) o de subajuste (cuando ambas pérdidas permanecen elevadas).

Figura 26*Training Loss vs epochs***Figura 27***Validation Loss vs epochs*

3.5.3.1 Análisis de Resultados

Mistral-8B-Instruct-2410-009 presentó una reducción relativa en Training Loss ($\approx 76.3\%$, de 1.424 a 0.3382), pero terminó con una Validation Loss relativamente alta ($\approx 72.8\%$, de 1.39 a 0.3784). La idea es que ambos porcentajes estén cerca uno del otro, lo cual es un indicador de que el modelo está generalizando bien.

Tabla 7

Valores de aprendizaje durante el entrenamiento

Modelo entrenado	Epochs	Loss training (valor inicial y valor final)	Validation Loss (Valor inicial - valor final)
Mistral-7B-Instruct-v0.3-JEP	10	1.1764 - 0.6775	1.15 - 0.9333
Mistral-8B-Instruct-2410-009	10	1.424 - 0.33	1.39 - 0.37
Llama-3.2-3B-Instruct-JEP	10	1.49 - 0.98	1.44 - 1.11
Llama-2-7B-Nous-Hermes-JEP	10	1.175 - 0.85	1.14 - 0.91
OpenHermes-2.5-Mistral-7B-JEP	10	1.0446 - 0.6796	1.066 - 0.87

3.5.3.2 Consideraciones Éticas y Licenciamiento

Todos los modelos de partida poseen licencias permisivas que autorizan el *fine-tuning*.

- Mistral-based $\Rightarrow$ Apache-2.0
- Llama-3.x $\Rightarrow$ Llama Community License v3.x
- Llama-2-7B-Nous-Hermes $\Rightarrow$ MIT

Se utilizó el dataset elaborado anteriormente con licencia **CC BY 4.0**, compatible con las licencias indicadas.


3.5.3.3 Alojamiento y Distribución de Modelos con Ajuste Fino

Los checkpoints resultantes se conservan en un esquema de almacenamiento redundante:

- **Réplica controlada** → repositorios **públicos** en *HuggingFace Hub* (Colección **Chatbot-JEP**, Figura 28). Una vez finalizadas las pruebas, estos repos se publicarán junto con los ficheros LoRA del modelo .

Figura 28

Colección en HuggingFace con los modelos después del ajuste fino



3.6 Pruebas Sobre los Modelos con Ajuste Fino

Para calificar el rendimiento real de cada modelo resultante, se compararon sus respuestas con las de referencia del split de prueba del dataset, como se muestra en la tabla 8. Se midieron las siguientes métricas:

- **BERTScore:** Calculado con la librería `bert_score` (modelo `microsoft/bert-base-multilingual-cased`, versión 0.3.13). BERTScore utiliza representaciones contextuales de palabras generadas por modelos como BERT para medir la similitud semántica entre la respuesta del sistema y la respuesta esperada. A diferencia de las métricas basadas en coincidencias exactas, BERTScore detecta equivalencias de significado aunque se usen términos diferentes, lo que es útil en tareas con múltiples respuestas válidas.
- **F1** a nivel de token. El F1-score es una métrica que combina precisión y exhaustividad para evaluar la exactitud de las respuestas generadas por el sistema. Se calcula a nivel de token comparando la coincidencia entre la respuesta generada y la respuesta de esperada, lo que permite medir qué tan completa y precisa es la información entregada.
- **Latencia** promedio de inferencia (Generación máx.150 tokens), en segundos. Considerando una generación máxima de hasta 150 tokens. Es un indicador clave de eficiencia, especialmente en contextos donde la velocidad de respuesta impacta directamente en la experiencia del usuario.

Tabla 8

Ejemplo prueba sobre modelo. Pregunta Generada vs Pregunta Esperada

Campo	Texto
Pregunta	¿Qué informe documenta la Operación Orión y su impacto en la Comuna 13 de Medellín?
Contexto	El informe 058-CI-01347 «Comuna 13: memorias de un territorio en resistencia» analiza la Operación Orión (octubre de 2002), la coordinación entre fuerza pública y paramilitares, las desapariciones forzadas y detenciones arbitrarias, así como la consolidación posterior del control armado y las resistencias comunitarias.
Respuesta esperada	El informe 058-CI-01347 «Comuna 13: memorias de un territorio en resistencia» detalla la Operación Orión y explica por qué este operativo es clave para entender las graves violaciones a los derechos humanos en la Comuna 13.
Respuesta generada	El informe 058-CI-01347 «Comuna 13: memorias de un territorio en resistencia» analiza la Operación Orión (octubre de 2002), la coordinación entre fuerza pública y paramilitares, las desapariciones forzadas y detenciones arbitrarias, así como la consolidación posterior del control armado y las resistencias comunitarias.
Latencia	6,501s
bert_score	81,9%
f1_score	43,4%

Cada modelo fue ejecutado utilizando el servicio en la nube **Google Colab**, que permite el uso de GPU para ejecutar *notebooks* en un entorno Python. Al aplicar la evaluación de las métricas sobre cada instancia del *split* de prueba, se obtuvieron los promedios que se presentan en la **tabla 9**.

Tabla 9

Modelos con ajuste fino. BertScore, F1 score y latencia

Modelo - HuggingFace ID	BERT Score (%)	F1 (%)	Latencia (s)	GPU
raulgdp/Mistral-8B-Instruct-2410-009	79,36	35,85	6,429	A100 40 GB
raulgdp/Mistral-7B-Instruct-v0.3-JEP	76,59	31,17	6,918	A100 40 GB
raulgdp/Llama-3.2-3B-Instruct-JEP	74,97	29,44	7,793	A100 40 GB
raulgdp/Llama-2-7B-Nous-Hermes-llama-JEP	73,80	31,1	6,660	A100 40 GB
raulgdp/OpenHermes-2.5-Mistral-7B-JEP	75,50	33,16	8,692	A100 40 GB

3.6.1 Análisis de Resultados

1. Precisión vs. velocidad

Mistral-8B-Instruct-2410-009 obtiene el mejor BERTScore y F1 manteniendo la

menor latencia (6.4 s). Esto lo convierte en el candidato óptimo para la capa RAG, ya que maximiza calidad sin sacrificar tiempo de respuesta.

2. Consistencia de la familia Mistral

Tanto la variante 7B como *OpenHermes-Mistral-7B* arrojan métricas competitivas (> 75 BERTScore), confirmando la robustez de la arquitectura Mistral tras el *fine-tuning*.

3. Modelos Llama 3.x frente a 2.x

Llama-3.2-3B supera a la versión 2-7B en todas las métricas, pero sigue por detrás de Mistral. La caída extrema de *Llama-2-7B-Nous-Hermes* (BERTScore ≈ 0.74) sugiere incompatibilidad con el dataset o sobreajuste severo.


4. Selección del modelo para RAG

Con base en estas métricas, se pre-selecciona **Mistral-8B-Instruct-2410-009** para integrarse en la arquitectura RAG.

3.7 RAG: Arquitectura General

El sistema de recuperación y generación se diseñó como un **flujo propio** construido sobre la librería **langchain-community**. Consta de tres fases: (1) indexado offline del corpus, (2) recuperación de contexto relevante, y (3) generación de la respuesta con el modelo preseleccionado (véase Figura 29).

Figura 29

Flujo pregunta respuesta

3.7.1 Indexado del Corpus

La **segmentación** de los documentos se realizó utilizando un **chunk_size** de **500 tokens** con un **chunk_overlap** de **50 tokens** para asegurar la continuidad semántica entre los segmentos. Para la generación de los *embeddings*, se empleó el codificador **sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2**, el cual produce vectores de **384 dimensiones**. Estos *embeddings* fueron almacenados en una **base de datos vectorial FAISS**, configurada con los parámetros por defecto y utilizando la **métrica de similitud del coseno**. Finalmente, la **persistencia** de este índice vectorial, junto con sus metadatos asociados, se gestionó mediante un **almacenamiento binario local** y en formato JSON.

3.7.2 Recuperación y Generación

1. **Consulta:** la pregunta del usuario se embebe con el mismo encoder MiniLM.
2. **Búsqueda:** se recuperan los `top_k = 3` chunks más similares (FAISS), cada uno con título de informe, descripción y enlace público.

3. Plantilla de ***prompt***:

«A continuación, se presenta una pregunta sobre el conflicto armado colombiano, junto con un contexto que proporciona información relevante. Escribe una respuesta que complete adecuadamente la solicitud.

Pregunta:

{pregunta}

Contexto:

{contexto}

Respuesta:

Generación: el *checkpoint* Mistral-8B-Instruct-2410-009 produce la respuesta con `temperature = 0.2, max_tokens = 150`.

4. **Post-procesado:** se trunca todo después de la cadena «Respuesta:» y se anexan las URLs de los documentos recuperados. Estas URLs se pueden obtener gracias al listado de informes publicado por La CEV (Informes y casos, 2022). Cuando se hace el indexado con FAISS, el identificador único del archivo es insertado en el

metadata, así podemos saber de qué archivo es el chunk o fragmento recuperado.

3.7.3 Rendimiento Operativo

La **latencia de búsqueda** en la base de datos vectorial FAISS, utilizando una CPU, fue de **40 segundos** para un conjunto de tres *chunks*. En cuanto a la **latencia de generación**, se observó un promedio de **6 segundos** al emplear una GPU A100.

3.7.4 Limitaciones Observadas

- **Latencia:** la fase de búsqueda incrementa el tiempo total de respuesta de 6 segundos (solo generación) a 46 segundos.
- **Cold-start:** reconstruir el índice exige $\approx 6h$ y RAM elevada.
- **Cobertura:** el encoder MiniLM puede degradar precisión en consultas con neologismos o jerga jurídica (*Paraphrase Multilingual MiniLM L12 V2 · Models · Dataloop, 2024*)

4. Pruebas y Resultados

4.1 Diseño de la Prueba

El objetivo principal fue evaluar la **calidad percibida** de las respuestas generadas por el sistema QA (RAG + Mistral-8B) según seis criterios: *Exactitud, Relevancia, Cobertura, Claridad, Justificación con evidencia y una evaluación general*. Cada criterio fue calificado en una escala del 1 al 5, siguiendo el formato de una escala tipo Likert.

4.1.1 Criterios para la evaluación de respuestas

- **Exactitud de la información:** Indica qué tan **correcta y libre de errores factuales** es la respuesta. La respuesta debe contener información verídica y precisa sobre el conflicto colombiano, sin datos incorrectos ni “**alucinaciones**” del modelo. Este criterio equivale a la **factualidad** de la respuesta. Por ejemplo, en evaluaciones de sistemas RAG se define *Correctness* como la exactitud factual de la información proporcionada (Yu et al., 2024).
- **Relevancia con respecto a la pregunta:** Mide en qué grado la respuesta **aborda la pregunta planteada** y se mantiene **pertinente al tema**. Una buena respuesta debe enfocarse en resolver la duda del usuario sobre el conflicto armado, sin divagar hacia información irrelevante. En otras palabras, la respuesta debe **alinearse con la intención y el contenido de la pregunta**, incluyendo solo datos relacionados (Yu et al., 2024).
- **Cobertura del contenido:** Refleja la **integralidad o exhaustividad** de la respuesta. Se evalúa si la respuesta **cubre todos los aspectos importantes** de la pregunta del usuario, o si deja lagunas. Una respuesta de alta calidad debe abordar **todas las**

facetas clave del tema preguntado, proporcionando un panorama completo (F. Xu et al., 2023) .

- **Claridad de redacción y comprensión:** Valora qué tan **clara, comprensible y bien estructurada** está la respuesta. Aquí se evalúa la **calidad de la redacción**, la organización de las ideas y si el lenguaje utilizado es apropiado para el público general. Una respuesta clara no debe ser ambigua ni excesivamente técnica (a menos que el público objetivo lo espere), y debe leerse de forma fluida.
- **Justificación o respaldo con evidencia:** Esta dimensión, crucial en sistemas RAG, se refiere a **qué tan bien la respuesta está respaldada por fuentes o explicaciones**. Dado que el sistema dispone de un módulo de recuperación, se espera que incorpore datos de documentos sobre el conflicto armado (Yu et al., 2024).
- **Evaluación general (opcional):** De manera global califica la calidad de la respuesta. Aunque esta prueba evalúa dimensiones específicas de la respuesta generada (exactitud, relevancia, cobertura, claridad y justificación), es importante recoger también una **percepción global** por parte del evaluador.

A continuación, se detalla la metodología empleada para la evaluación del sistema, incluyendo la descripción de los participantes, el instrumento utilizado, el procedimiento seguido y las herramientas de análisis de datos (véase Tabla 10).

Tabla 10*Metodología prueba con usuarios*

Elemento	Descripción
Participantes	10 evaluadores (18 - 35 años, formación universitaria, Universidad del Valle) afirman tener conocimiento básico o nulo en el conflicto armado colombiano. Los cuales consultan información al respecto de manera ocasional.
Instrumento	Encuesta en Google Forms para obtener los datos básicos del evaluador y preguntas para que el sistema responda.
Procedimiento	Cada evaluador propuso libremente de 1 a 2 preguntas (total 15). Tras recibir la respuesta y las tres fuentes citadas por el RAG, calificó los seis ítems en una hoja de cálculo.
Herramientas de análisis	Exportación a CSV → Excel / pandas para estadística descriptiva

4.2 Resultados cuantitativos

El análisis de la **Figura 30** muestra que el conocimiento de los participantes sobre el conflicto armado colombiano es predominantemente limitado: el 42,9 % reportó un nivel básico, mientras que el 28,6 % indicó no tener ningún conocimiento y otro 28,6 % un nivel intermedio. Por su parte, la **Figura 31** revela que el 71,4 % de los encuestados consulta

información sobre el tema solo ocasionalmente y un 14,3 % nunca lo hace. Estos resultados sugieren que la mayoría del público evaluador no está altamente familiarizado con el conflicto, lo cual es útil para analizar cómo responde el sistema ante usuarios no expertos. En la **Tabla 11** se proporciona un ejemplo de pregunta propuesta por los participantes que refleja este nivel de conocimiento.

Figura 30

Conocimiento de los evaluadores sobre el conflicto armado

Conocimiento previo sobre el conflicto armado colombiano




Figura 31

Frecuencia de consulta de información sobre el conflicto armado colombiano

¿Con qué frecuencia has leído o consultado información sobre el conflicto armado colombiano?




Tabla 11

Ejemplo evaluado de una instancia del sistema de pregunta-respuesta

Pregunta	Como esta actualmente el conflicto armado colombiano?, puede afectar aun civil más de la Ciudad de Cali ahora mismo?
Respuesta	El conflicto armado colombiano sigue afectando a la población civil, especialmente en zonas rurales y áreas con presencia de grupos armados. La violencia contra líderes sociales y defensores de derechos humanos ha aumentado desde la firma del Acuerdo de Paz con las FARC en 2016. Además, el narcotráfico y el narcoterrorismo continúan siendo problemas significativos, con grupos como el Clan del Golfo y las disidencias de las FARC involucrados en actividades ilícitas. La respuesta del Estado ha sido insuficiente, y la impunidad persiste en muchos casos.
Fuentes	Retos humanitarios 2021 Colombia - Documento: http://archivo.comisiondelaverdad.co/explora/detalle/066-CI-01215 Una mirada del atentado al avión de Avianca. Narcotráfico y narcoterrorismo en el conflicto armado colombiano - Documento: http://archivo.comisiondelaverdad.co/explora/detalle/066-CI-00897 ¿Cuáles son los patrones?: asesinatos de líderes sociales en el post acuerdo - Documento: http://archivo.comisiondelaverdad.co/explora/detalle/119-CI-00047
Exactitud de la información	4
Relevancia con respecto a la pregunta	4
Cobertura del contenido	3
Claridad de redacción y comprensión	5
Justificación o respaldo con evidencia	5

Resultados Promedio

Tabla 12

Resultados promedio de la evaluación con usuarios

Criterio	Promedio	Desviación estándar
Exactitud de la información	3.27	1.30
Relevancia respecto a la pregunta	3.63	1.35
Cobertura del contenido	3.0	1.38
Claridad de redacción y comprensión	3.72	1.29
Justificación / respaldo con evidencia	3.45	1.37
Evaluación general	3.27	1.08

Los valores se sitúan ligeramente por encima del punto medio (3), mostrando una aceptación moderada. La claridad y la justificación destacan como los aspectos mejor puntuados, mientras que la cobertura recibe la valoración más baja.

4.3 Resultados Cualitativos

Entre los comentarios más frecuentes que surgieron durante la evaluación se destacó, en primer lugar, la **falta de profundidad**: los participantes percibieron que las respuestas ofrecidas por el sistema resultaban demasiado generales y breves, sobre todo

cuando la pregunta requería un análisis multidimensional —histórico, social o político— del conflicto. En segundo término, se subrayó la necesidad de una **mayor precisión en los detalles**; los evaluadores reclamaron la inclusión de fechas y el nombre exacto de las instituciones pertinentes, así como la eliminación de repeticiones textuales que restan claridad.

A partir de estas observaciones, los evaluadores formularon varias **recomendaciones** concretas: ampliar las explicaciones en los temas complejos para cubrir todos sus matices, verificar y actualizar los datos institucionales —especialmente programas vigentes y normativas— y, finalmente, suprimir redundancias mientras se afina la exactitud de los nombres propios y demás referencias puntuales.

Ejemplos de Feedback:

- “La respuesta menciona ‘reparación integral’ pero no explica los mecanismos específicos.”
- “Sería útil citar la ley exacta y la fecha.”

4.3.1 Análisis de las Respuestas Generadas

- El sistema limita el contexto a **tres documentos** y la generación a **150 tokens**, lo que recorta la profundidad cuando la pregunta abarca varios subtemas.
- El 40 % de las respuestas fueron catalogadas como **parciales** (no abordan todos los puntos), 53 % **correctas**, y 7 % **fuera de alcance**.

4.4 Límites del Estudio

- El alcance de la encuesta presenta varias limitaciones que conviene tener en cuenta al interpretar los resultados. En primer lugar, **el tamaño de la muestra fue reducido** y los participantes se reclutaron por conveniencia entre compañeros de ingeniería de una misma universidad. Esta combinación genera un riesgo claro de sesgo de selección: las valoraciones reflejan sobre todo la perspectiva de un grupo homogéneo en edad, formación y familiaridad tecnológica, por lo que difícilmente pueden extrapolarse a otros públicos —periodistas, víctimas, investigadores sociales— que buscarían información más especializada o tendrían expectativas distintas frente al sistema.
- En segundo lugar, **ninguno de los evaluadores era especialista en el conflicto armado colombiano**. Aunque el instrumento medía percepciones de claridad, relevancia o cobertura, la ausencia de expertos impidió contrastar la exactitud factual de las respuestas con conocimiento historiográfico o jurídico de alto nivel. De este modo, la métrica de “exactitud” se apoyó en la intuición de los usuarios y no en una verificación rigurosa de datos, fechas o citas normativas.
- Por último, **las preguntas utilizadas para la prueba no siguieron un nivel de dificultad controlado**: cada evaluador formuló sus propias consultas, lo que introdujo una variabilidad considerable en extensión, complejidad y enfoque temático. Esta heterogeneidad dificulta la comparación directa de las calificaciones y puede ocultar patrones sistemáticos de rendimiento; por ejemplo, un modelo podría responder bien a preguntas cortas y mal a preguntas analíticas, pero el diseño actual no permite aislar ese efecto. En conjunto, estas limitaciones sugieren la necesidad

de futuras evaluaciones con muestras más amplias y diversificadas, inclusión de expertos y un banco de preguntas calibrado para medir desempeño por niveles de dificultad.

4.5 Conclusiones de las Pruebas

El sistema evaluado demuestra un desempeño aceptable en términos de claridad y relevancia, lo que indica que es capaz de generar respuestas comprensibles y pertinentes a las preguntas planteadas por usuarios no expertos. Sin embargo, presenta deficiencias importantes en cobertura y profundidad analítica, especialmente ante consultas que requieren una mirada más compleja y multidimensional del conflicto armado colombiano.

Los resultados cualitativos refuerzan esta conclusión, al evidenciar que las respuestas tienden a ser breves, generales y carentes de detalle específico —como fechas, normativas o nombres institucionales— lo cual limita su utilidad informativa en contextos más exigentes.

En consecuencia, se proponen las siguientes acciones de mejora para optimizar la calidad del sistema:

- **Aumentar el límite de tokens generados (`max_tokens`)** y permitir cadenas de seguimiento para preguntas extensas, lo que permitiría al modelo desarrollar respuestas más completas y contextualizadas.
- **Ampliar el número de documentos recuperados (`top_k ≥ 5`)** e incorporar una etapa de *re-ranking* de evidencias que priorice fuentes más relevantes y complementarias para enriquecer la generación.

- **Incluir mecanismos de validación factual en el postprocesamiento**, como *Toolformer* o contrastes automáticos con bases de datos legislativas o historiográficas, para asegurar mayor precisión en datos sensibles.

Estas medidas permitirían no solo mejorar la calidad técnica de las respuestas, sino también adaptarlas mejor a las expectativas de distintos perfiles de usuario —desde el público general hasta investigadores y periodistas— elevando así el valor práctico del sistema en escenarios reales de consulta.

5. Conclusiones y Trabajo Futuro

5.1 Conclusiones

Este trabajo de grado demuestra la viabilidad técnica y conceptual de desarrollar un sistema de pregunta-respuesta (QA) especializado en los informes de la Comisión Para El Esclarecimiento de La Verdad sobre el conflicto armado colombiano. A través del uso de técnicas de Recuperación Aumentada con Generación (RAG) y el ajuste fino (fine-tuning) de modelos ligeros de lenguaje, se logró construir una herramienta que permite acceder de forma eficiente y precisa a información compleja y extensa. Se logró:

- Crear un dataset robusto con más de 2.800 instancias QA, incluyendo datos sintéticos generados con LLMs avanzados.
- Afinar varios modelos de lenguaje, donde **Mistral-8B-Instruct-2410-009** demostró el mejor equilibrio entre precisión y velocidad, siendo ideal para entornos RAG.
- Implementar un sistema funcional con recuperación de contexto vía FAISS, integración con modelos LLM y evaluación mediante métricas automáticas (BERTScore, F1) y pruebas con usuarios.

Sin embargo, el sistema presenta desafíos como la latencia de recuperación, la dependencia del formato y calidad de los documentos originales, y la necesidad de mejorar la cobertura semántica frente a jergas o consultas complejas.

5.2 Trabajo Futuro

A partir de los resultados obtenidos, se identifican múltiples líneas de trabajo para extender y mejorar este sistema:

1. Evaluación holística del sistema RAG

- Implementar un protocolo de prueba que calcule **BERTScore, F1 y latencia** sobre el sistema completo (recuperador + generador), empleando el modelo **Mistral-8B-Instruct-2410-009** ya integrado.
- Comparar estas métricas con las obtenidas en el modelo sin RAG para estimar la ganancia real que aporta la recuperación de contexto.
- Diseñar o ampliar el *dataset* con preguntas cuyo contexto proceda de múltiples informes, de modo que la evaluación refleje escenarios en los que la capa RAG puede enriquecer la respuesta.
- Documentar y discutir los resultados, destacando casos en los que RAG mejore o deteriore la precisión, la cobertura y el tiempo de respuesta.

2. Optimización de latencia:

- Migrar la recuperación a entornos con GPU o FAISS en GPU.
- Incorporar técnicas como la compresión de embeddings o vector stores jerárquicos.

3. Ampliación temática:

- Expandir el sistema a otros temas relevantes para la historia reciente de Colombia (acuerdos de paz, procesos de justicia transicional).

4. Multimodalidad:

- Incluir soporte para imágenes, audios y videos relacionados con el conflicto armado (testimonios, mapas, etc.).

5. Entrenamiento con retroalimentación humana (RLHF):

- Incorporar retroalimentación humana en el fine-tuning para mejorar la calidad de las respuestas y reducir sesgos.

6. Interfaz conversacional avanzada:

- Implementar un chatbot con manejo de contexto conversacional y seguimiento de diálogos complejos.

7. Evaluación a gran escala y medición de impacto social:

- Ejecutar estudios con más participantes y grupos sociales diversos para medir comprensión, utilidad percibida e impacto en educación y memoria histórica.

8. Internacionalización del sistema:

- Traducir e implementar versiones en inglés u otros idiomas para comunidades académicas o migrantes colombianos interesados en el tema.

6. Bibliografía

- Nadkarni, P. M., Ohno-Machado, L., & Chapman, W. W. (2011). Natural language processing: an introduction. *Journal of the American Medical Informatics Association*, 18(5), 544-551.
- ArcGIS. (n.d.). *Datasets de entidades en ArcGIS*. Datasets de entidades en ArcGIS Pro—ArcGIS Pro | Documentación. Retrieved May 27, 2024, from <https://pro.arcgis.com/es/pro-app/latest/help/data/feature-datasets/feature-datasets-in-arcgis-pro.htm>
- Brazdil, P., van Rijn, J. N., Soares, C., & Vanschoren, J. (2022). *Metalearning: Applications to Automated Machine Learning and Data Mining*. Springer International Publishing. https://doi.org/10.1007/978-3-030-67024-5_4
- Caballero, M. (2021). A Brief Survey of Question Answering Systems. *International Journal of Artificial Intelligence & Applications*, Vol.12(5). <https://ssrn.com/abstract=3996229>
- Chase, H. (2023, 04). "document question-answering" applications is a retrieval step,. x.com. Retrieved May 27, 2024, from <https://x.com/hwchase17/status/1649428297816711174/photo/1>
- Comisión De La Verdad. (2017, Abril 5). *Página Principal - Comisión De La Verdad*. Inicio | Informe Final Comisión de la Verdad. Retrieved April 19, 2024, from <https://www.comisiondelaverdad.co/>
- Comisión De La Verdad. (2022). *Analítica de datos (información y recursos) | Informe Final Comisión de la Verdad*. Anexo. Retrieved May 16, 2024, from <https://www.comisiondelaverdad.co/analitica-de-datos-informacion-y-recursos#c2>
- Comisión De La Verdad. (2022). *Metodología de análisis de entrevistas utilizando Procesamiento de Lenguaje Natural (PLN)*. Comisión. Retrieved May 27, 2024, from https://www.comisiondelaverdad.co/sites/default/files/descargables/2022-08/03_Anejo_NLP_07312022_4%2C9KB.pdf

- Comisión de la Verdad. (2022). Hay futuro si hay verdad | Informe Final Comisión de la Verdad. Comisión de la Verdad. Retrieved June 26, 2024, from <https://www.comisiondelaverdad.co/hay-futuro-si-hay-verdad>
- DANE. (2017). *Encuesta Nacional de Lectura - ENLEC 2017*. DANE Información Para Todos. Retrieved 06 21, 24, from https://sitios.dane.gov.co/enlec_dashboard/#/
- Deepset.ai. (2023, September 29). *Fine-tuning large language models*. Deepset. Retrieved May 27, 2024, from <https://www.deepset.ai/blog/llm-finetuning>
- GIRALDO HOYOS, D. A. (2016, 7 15). *ASISTENTE VIRTUAL CHATBOT PARA LA WEB DE LA UNIVERSIDAD DEL VALLE*. <https://acortar.link/l8kWsd>
- Google AI. (2023). *Google Gemini*. Gemini - chat to supercharge your ideas. Retrieved May 16, 2024, from <https://gemini.google.com/app>
- Hardesty, L. (2017, April 14). *Explained: Neural networks*. MIT News. Retrieved May 27, 2024, from <https://news.mit.edu/2017/explained-neural-networks-deep-learning-0414>
- Henao, J. (2022). *gpt2-small-spanish-historias-conflicto-col*. huggingface.co. Retrieved May 27, 2024, from <https://huggingface.co/jorge-henao/gpt2-small-spanish-historias-conflicto-col>
- H. Renear, A., Sacchi, S., & M. Wickett, K. (2011, 02). Definitions of Dataset in the Scientific and Technical Literature. <https://doi.org/10.1002/meet.14504701240>
- HuggingFace. (n.d.). *Hugging Face – The AI community building the future*. The collaboration platform. Retrieved June 25, 2024, from <https://huggingface.co/>
- Ji, Y., Wang, Q., & Li, X. (2019). A Survey on Tensor Techniques and Applications in Machine Learning. *IEEE Access*, 7. 10.1109/ACCESS.2019.2949814
- Kaur, P., Siddharth Kashyap, G., Kumar, A., Nafis, T., Kumar, S., & Shokeen, V. (2024). From Text to Transformation: A Comprehensive Review of Large Language Models' Versatility. <https://doi.org/10.48550/arXiv.2402.16142>
- La Web del Programador. (n.d.). *DICCIONARIO INFORMÁTICO*. Retrieved April 19, 2024, from <https://www.lawebdelprogramador.com/>

Legislación Colombiana. (n.d.). *DECRETO 588 DE 2017*.

<https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=80633>

Lin, X., Wang, W., & Li, Y. (2024, Enero 30). Data-efficient Fine-tuning for LLM-based

Recommendation. *arXiv - Cornell University*. <https://arxiv.org/abs/2401.17197>

Minaee, S., & Mikolov, T. (2024, Feb 20). Large Language Models: A Survey. *arXiv*.

PlanTL-GOB. (2023, October 12). *PlanTL-GOB-ES/roberta-large-bne-sqac · Hugging Face*.

Hugging Face. Retrieved May 27, 2024, from

<https://huggingface.co/PlanTL-GOB-ES/roberta-large-bne-sqac>

Quinn, J., McEachen, J., Fullan, M., Gardner, M., & Drummy, M. (2019). *Dive Into Deep*

Learning: Tools for Engagement. SAGE Publications.

Universidad De Los Andes. (2024). *Datasets de Administración*. Datasets de administración

- Facultad de Administración. Retrieved May 27, 2024, from

<https://uniandes-co.libguides.com/administracion/datasets>

Vaswani, A., Shazeer, N., & Parmar, N. (2017). Attention Is All You Need. *ArXiv*. ArXiv.

10.48550/arXiv.1706.03762 Focus to learn more.

Xu, R., Feng, Y., & Chen, H. (2023). ChatGPT vs. Google: A Comparative Study of Search

Performance and User Experience. doi:10.48550/ARXIV.2307.01135

Douze, M., Guzhva, A., Deng, C., Johnson, J., Szilvasy, G., Mazaré, P.-E., ... Jégou, H.

(2024). The Faiss library. doi:10.48550/ARXIV.2401.08281

Team, G., Riviere, M., Pathak, S., Sessa, P. G., Hardin, C., Bhupatiraju, S., Hussenot, L.,

Mesnard, T., Shahriari, B., Ramé, A., Ferret, J., Liu, P., Tafti, P., Friesen, A., Casbon,

M., Ramos, S., Kumar, R., Lan, C. L., Jerome, S., . . . Andreev, A. (2024). Gemma 2:

Improving Open Language Models at a Practical Size. *arXiv (Cornell University)*.

<https://doi.org/10.48550/arxiv.2408.00118>

Zhang, P., Zeng, G., Wang, T., & Lu, W. (2024). TinyLlama: an Open-Source Small

Language Model. *arXiv (Cornell University)*.

<https://doi.org/10.48550/arxiv.2401.02385>

Grattafiori, A., Dubey, A., Jauhri, A., Pandey, A., Kadian, A., Al-Dahle, A., ... Ma, Z. (2024).

The Llama 3 herd of models. doi:10.48550/ARXIV.2407.21783

Comisión Para El Esclarecimiento de La Verdad. (2022). Informes y casos. Comisión de la

Verdad. Recuperado 1 de septiembre de 2024, de

<https://www.comisiondelaverdad.co/informes-y-casos>

Introducing GPT-4.1 in the API. (2025). Recuperado 24 de mayo de 2025, de

<https://openai.com/index/gpt-4-1/>

Xu, L., Xie, H., Qin, S. J., Tao, X., & Wang, F. L. (2023). Parameter-Efficient Fine-Tuning

Methods for Pretrained Language Models: A Critical Review and Assessment. arXiv

(Cornell University). <https://doi.org/10.48550/arxiv.2312.12148>

Paraphrase multilingual MiniLM L12 V2 · Models · Dataloop. (2024).

https://dataloop.ai/library/model/sentence-transformers_paraphrase-multilingual-minilm-l12-v2/

Yu, H., Gan, A., Zhang, K., Tong, S., Liu, Q., & Liu, Z. (2024). Evaluation of

Retrieval-Augmented Generation: A Survey. arXiv (Cornell University).

<https://doi.org/10.48550/arxiv.2405.07437>

Xu, F., Song, Y., Iyyer, M., & Choi, E. (2023). A Critical Evaluation of Evaluations for

Long-form Question Answering. arXiv (Cornell University).

<https://doi.org/10.48550/arxiv.2305.18201>

7. Anexos

Anexo A

Enlaces relevantes

- Código fuente: <https://github.com/Iron-mind/colombian-conflict-chatbot>
- Carpeta drive con todos los informes obtenidos solo tiene acceso correos institucionales de univalle: [Drive](#)
- Colección de modelos con ajuste fino en HuggingFace: [chatbot-JEP](#)
- Formulario de google utilizado para evaluar el sistema: [Formulario](#)

Anexo B

Formulario de evaluación usado en pruebas con usuarios

Edad

Selecciona tu rango de edad:

- Menos de 18 años
 - 18 a 24 años
 - 25 a 34 años
 - 35 a 44 años
 - 45 a 54 años
 - 55 años o más
 - Prefiero no responder
-

Nivel educativo alcanzado

Marca el nivel educativo más alto que has completado:

- Educación básica (primaria o secundaria)

- Educación media (bachillerato)
 - Educación técnica o tecnológica
 - Educación universitaria (pregrado)
 - Posgrado (maestría o doctorado)
 - Prefiero no responder
 - Otro: _____
-

¿Qué carrera estás estudiando actualmente?

Si estás cursando estudios en este momento, indica el nombre de tu carrera o programa académico:

[Campo de texto abierto]

¿En qué trabajas actualmente?

Si te encuentras trabajando, describe tu ocupación, profesión o área laboral:

[Campo de texto abierto]

Nivel de conocimiento sobre el conflicto armado colombiano

¿Cómo calificarías tu conocimiento sobre el conflicto armado colombiano?

- Ninguno
 - Básico
 - Intermedio
 - Avanzado
 - Experto
-

Frecuencia de consulta de información sobre el conflicto armado colombiano

¿Con qué frecuencia sueles leer o buscar información sobre el conflicto armado colombiano?

- Nunca
 - Ocasionalmente
 - Una vez al mes
 - Una vez a la semana
 - Con frecuencia (más de una vez por semana)
-

Fuentes consultadas sobre el conflicto armado colombiano

¿Qué tipo de fuentes sueles consultar sobre el conflicto armado colombiano?

(Marca todas las que correspondan)

- Noticias (prensa escrita, radio, televisión)
 - Libros académicos o de historia
 - Documentos oficiales (informes, sentencias, etc.)
 - Redes sociales
 - Videos o documentales
 - No suelo consultar fuentes sobre el tema
 - Otro: _____
-

Pregunta para el sistema

Escribe una o más preguntas sobre el conflicto armado colombiano que te gustaría que el sistema responda. Trata de formularlas con claridad y especificidad:

[Campo de texto abierto]

Evaluación

Los aspectos a evaluar son los que ves en la imagen puntuando del 1 al 5. Puedes evaluar la calidad de la respuesta del 1 al 5 teniendo en cuenta lo siguiente.

1 – Muy baja

2 – Baja

3 – Media

4 – Alta

5 – Muy alta

	EXACTITUD DE LA INFORMACIÓN Evalúa si la respuesta es correcta y libre de errores.
	RELEVANCIA CON RESPECTO A LA PREGUNTA Mide qué tan pertinente es la respuesta en relación con la pregunta formulada.
	COBERTURA DEL CONTENIDO Valora si la respuesta aborda todos los aspectos importantes de la pregunta
	CLARIDAD DE REDACCIÓN Y COMPRENSIÓN Determina si la respuesta está bien redactada y resulta fácil de entender
	JUSTIFICACIÓN O RESPALDO CON EVIDENCIA Considera que las fuentes entregadas por el sistema son válidas y coherentes con la respuesta
	EVALUACIÓN GENERAL (OPCIONAL) Ofrece una valoración global sobre la calidad de la respuesta

El evaluador da su calificación llenando un formato como el de la tabla 11

Anexo 4

Listado de informes excluidos a la hora de la descarga

- [086-CI-02037](#) | Enlace no disponible
- [119-CI-00038](#) | Enlace no disponible
- [1306-CI-01928](#) | Contiene material en formato de video
- [1308-CI-02023](#) | Enlace no disponible
- [365-CI-01335](#) | Recurso en formato de video
- [365-CI-01580](#) | Enlace no disponible
- [365-CI-01661](#) | Recurso en formato de video
- [365-CI-01931](#) | Recurso en formato de video
- [748-CI-00535](#) | Enlace no disponible
- [748-CI-00847](#) | Enlace no disponible
- [748-CI-00870](#) | Recurso en formato de video
- [975-CI-00913](#) | Enlace no disponible